



Universidad del Valle

PROYECTO DE CIENCIA DE DATOS

Incidencia Notificada de
Dengue

Felipe Ortiz Calan - 2380642
Santiago Hernandez - 2380367
Santiago Velasquez - 2380378
Nicolas chaparro - 2380530
Gustavo Restrepo - 2380618

1. Preguntas de Negocio Abordadas

1. ¿En qué combinaciones de tiempo, territorio y perfil se concentra la notificación?
2. ¿Cuáles son los municipios líderes dentro de cada departamento?
3. ¿Qué municipios concentran más casos al unir hechos con la dimensión territorial?
4. ¿Cómo cambia semanalmente el volumen nacional de notificaciones?
5. ¿Qué perfiles de edad y sexo concentran los registros?
6. ¿Qué departamentos presentan mayor hospitalización registrada?

2. Contexto del Análisis

Este análisis examina **581,071 registros** de notificación de dengue del Sistema Nacional de Vigilancia en Salud Pública (SIVIGILA) para el período **2022-2025**, distribuidos en **33 departamentos** y cientos de municipios. Los datos proceden de reportes de incidencia semanal, agrupados por geografía (departamento, municipio, área), temporalidad (año, semana) y características demográficas (edad, sexo).

El objetivo es transformar registros transaccionales en una estructura optimizada para vigilancia epidemiológica, análisis de tendencias y priorización de intervenciones en salud pública.

3. Diseño Lógico de la Bodega de Datos


Modelo Estrella (Star Schema)

Para estructurar la información, se ha implementado un **Modelo Estrella**. Se seleccionó este modelo por encima de una arquitectura en Copo de Nieve debido a tres ventajas técnicas fundamentales:

1. **Rendimiento analítico (OLAP):** Al mantener las dimensiones planas (ej. el municipio y el departamento en la misma tabla), se minimiza la cantidad de saltos (**JOINS**) que el motor de base de datos debe realizar, acelerando drásticamente las sumatorias y agrupaciones históricas.
2. **Usabilidad:** Facilita la escritura de consultas SQL complejas y se integra de forma nativa y eficiente con herramientas de Inteligencia de Negocios.
3. **Granularidad óptima:** Permite escalar el nivel de detalle sin alterar la estructura principal.

El modelo diseñado consta de una tabla de hechos principal (**fact_incidencia**), la cual captura el volumen de casos y las hospitalizaciones, rodeada por cinco dimensiones que le otorgan contexto al dato: temporalidad (**dim_tiempo**), ubicación espacial (**dim_geografia**), características sociodemográficas (**dim_perfil_demografico**), determinantes sociales (**dim_vulnerabilidad**) y el rigor del criterio médico (**dim_confirmacion_diagnostica**).

A continuación, se presenta el diagrama entidad-relación del modelo y la justificación técnica detallada de la granularidad y atributos de cada una de sus tablas.



1. Tabla de Hechos: Incidencia (fact_incidencia)

Es el corazón analítico de nuestra bodega. En lugar de consultar una tabla pesada con millones de registros individuales por paciente, esta tabla condensa la información. Su trabajo es responder rápidamente las preguntas cuantitativas: cuánta gente se enfermó y cuánta terminó en un hospital bajo ciertas condiciones.

- **Granularidad:** El nivel de máximo detalle es el grupo de pacientes que comparten exactamente la misma semana, municipio, perfil demográfico, vulnerabilidad y tipo de diagnóstico.
- **Atributos clave:** Las cinco llaves foráneas que la conectan con las dimensiones, más dos métricas (hechos): `casos_totales` (conteo) y `casos_hospitalizados` (sumatoria).

2. Dimensión de Tiempo (dim_tiempo)

El Dengue es una enfermedad altamente estacional. Para que los analistas puedan identificar patrones, evaluar picos de contagio o comparar brotes entre distintos años, necesitamos aislar la variable temporal.

- **Granularidad:** Semana epidemiológica (el estándar de medición en salud pública, más preciso que el mes).
- **Atributos clave:** `id_tiempo` (formato numérico de Año + Semana, ej. 202305), `anio`, `semana_epidemiologica`.

3. Dimensión Geográfica (dim_geografia)

La propagación del mosquito transmisor está ligada al clima, la altitud y la región. Esta dimensión permite mapear territorialmente los brotes, facilitando a las secretarías de salud saber exactamente en qué departamentos o municipios deben enfocar las fumigaciones y campañas.

- **Granularidad:** Nivel de municipio (basado en el código oficial del DANE).
- **Atributos clave:** `id_geografia` (Código del municipio), `cod_departamento`, `nombre_departamento`, `nombre_municipio`.

4. Dimensión de Perfil Demográfico (dim_perfil_demografico)

Nos permite entender el rostro de la enfermedad. Agrupar a los pacientes por su rango de edad, sexo y régimen de salud ayuda a descubrir, por ejemplo, si los niños de zonas rurales están siendo más afectados que los adultos en zonas urbanas.

- **Granularidad:** Una combinación única de sexo, grupo etario, tipo de área y régimen de seguridad social.
- **Atributos clave:** `id_perfil` (llave subrogada autoincremental), `sexo`, `grupo_etario` (categorizado en rangos como 0-5 años, 15-28 años, etc.), `area` (rural o urbana), `tip_ss`.

5. Dimensión de Vulnerabilidad (dim_vulnerabilidad)

Los determinantes sociales impactan directamente en el riesgo de contagio y en la gravedad del cuadro clínico. Aislar estas variables permite hacer análisis de equidad en salud, cruzando la incidencia del Dengue con factores como la pobreza, el desplazamiento forzado o la pertenencia étnica.

- **Granularidad:** Combinación única del estrato socioeconómico y las condiciones especiales del paciente.
- **Atributos clave:** **id_vulnerabilidad** (llave subrogada autoincremental), **estrato**, **per_etn** (etnia), **gp_desplaz** (desplazado), **gp_migrant** (migrante), **gp_gestan** (gestante).


6. Dimensión de Confirmación Diagnóstica (dim_confirmacion_diagnostica)

En vigilancia en salud pública, un caso "sospechoso" no tiene el mismo rigor de datos que un caso "confirmado por laboratorio". Esta dimensión es vital para la calidad del dato, permitiendo a los epidemiólogos filtrar el análisis según la certeza médica del reporte.

- **Granularidad:** El método exacto utilizado para diagnosticar e ingresar al paciente al sistema.
- **Atributos clave:** **id_confirmacion** (llave subrogada autoincremental), **codigo_tipo_caso** (código oficial de SIVIGILA), **metodo_confirmacion** (descripción textual del diagnóstico).

4. Hallazgos Clave

Hallazgo 1: Concentración Territorial Extrema




Interpretación: El análisis revela una concentración extremadamente pronunciada de casos en apenas 10 municipios. **Cali encabeza con 51,561 registros** (8.9% del total nacional), seguida por Ibagué (18,663) y Barranquilla (17,922). Los municipios del Valle del Cauca, Tolima y Atlántico dominan los registros totales, sugiriendo que estos territorios concentran la vigilancia más activa o potencialmente una mayor circulación viral.

Implicaciones Operativas: Estos hallazgos orientan la priorización de recursos de vigilancia, respuesta y comunicación de riesgos. Sin embargo, es crítico validar si la concentración refleja incidencia real o diferencias en calidad del reporte y capacidad de diagnóstico entre territorios.

Limitación Crítica: Los registros no son equivalentes a incidencia poblacional. Sin denominadores de población de cada municipio, no es posible afirmar que Cali tenga mayor riesgo relativo que municipios más pequeños. La interpretación requiere integración de datos de población del DANE.

Hallazgo 2: Picos Estacionales y Tendencias Temporales




Interpretación: La serie temporal identifica patrones cíclicos con incrementos progresivos en 2024. Los picos oscilan entre 1,000 y 1,800 registros semanales, con variabilidad que refleja tanto cambios en transmisión como en capacidad de vigilancia. **El año 2024 mostró los mayores volúmenes históricos**, particularmente en semanas 14-25 (abril-junio).

Hallazgos Principales:

- Patrón recurrente: Picos concentrados en semanas primaverales (abril-junio) cada año
- 2024 registró máximos históricos, sugiriendo cambio en epidemiología o mejora en reporte
- Variación semana a semana alcanza $\pm 15\%$, indicando volatilidad en notificaciones

Contexto Epidemiológico: Los picos pueden asociarse a: (1) variabilidad ambiental (lluvia, temperatura); (2) vacíos de vigilancia recuperados; (3) brotes reales. Se requiere integrar datos meteorológicos y de actividad de vigilancia para discriminar causas.

Hallazgo 3: Perfil Demográfico con Predominio Pediátrico



Interpretación: El análisis demográfico revela que la mayoría de casos notificados se concentran en niños y jóvenes de 5-24 años, con aproximadamente 60% del volumen total. **El grupo 5-14 años encabeza con 209,521 casos**, seguido por 15-24 años con 126,636. La distribución por sexo es equilibrada en la mayoría de grupos etarios, sin diferencias marcadas.

Hallazgos Principales:

- Edades escolares (5-24 años) concentran más del 60% de todos los registros
- Predominio leve de mujeres (F) en la mayoría de grupos de edad
- Carga baja en menores de 5 años y adultos mayores (>65)

Limitación Crítica: Esta distribución DESCRIBE la estructura de notificaciones del dataset, no equivale a incidencia real por grupo etario. Sin datos de población por grupo etario del DANE, no es posible calcular tasas de riesgo relativo. El predominio de edades escolares puede reflejar: (1) mayor transmisión en esas edades; (2) mejor acceso a diagnóstico en espacios escolares; (3) notificación preferencial de este segmento.

5. Limitaciones Críticas del Análisis

- 1. Ausencia de datos poblacionales:** Los registros notificados no son tasas de incidencia. Un municipio con 100 notificaciones puede tener incidencia muy diferente según su población. Sin denominadores poblacionales, no es posible comparar riesgo relativo entre territorios.
- 2. Datos de notificación, no de incidencia real:** El Parquet captura solo casos reportados al SIVIGILA. La incidencia poblacional es desconocida; hay subnotificación incontable y variable según territorio y acceso al sistema de salud.
- 3. Falta de información clínica:** El dataset carece de gravedad clínica, complicaciones, desenlaces, factores de riesgo individual y contexto de viaje. Esto limita análisis de factores de riesgo y pronósticos.
- 4. Cobertura desigual de vigilancia:** Departamentos y municipios difieren en capacidad diagnóstica, motivación de reporte y oportunidad de notificación, inflando o minimizando los números de forma sistemática.
- 5. Codificación incompleta:** Campos como AREA, SEXO y PAC_HOS tienen valores faltantes o inconsistentes. Interpretación requiere validación previa.
- 6. Período limitado:** 2022-2025 no es suficiente para distinguir tendencias seculares de variabilidad estacional a largo plazo.

6. Próximos Pasos Recomendados

- 1. Integración de datos poblacionales:** Obtener proyecciones de población DANE por municipio y grupo etario para calcular tasas de incidencia e incidencia acumulada reales.
- 2. Análisis de variables meteorológicas:** Vincular temperatura, precipitación y humedad para investigar drivers ambientales de picos estacionales y variabilidad temporal.
- 3. Validación de calidad de datos:** Auditar registros con valores extremos (edad > 120, coordenadas inválidas) e investigar municipios con gaps de reporte para identificar sesgos.
- 4. Análisis geoespacial:** Mapeo por coordenadas de municipio para identificar clusters espaciales y detectar dispersión geográfica de casos.
- 5. Modelado predictivo:** Entrenar modelos ARIMA, Prophet o redes neuronales para pronosticar incidencia en semanas futuras y detectar anomalías.
- 6. Análisis de factores de riesgo:** Estudiar asociaciones entre hospitalización y variables demográficas (edad, sexo, área) e integrar información clínica complementaria.

7. Repositorio del Proyecto

El código fuente y los materiales de este proyecto de ciencia de datos sobre la incidencia notificada de dengue se encuentran disponibles en el siguiente repositorio de GitHub:

Enlace: <https://github.com/bypipe27/grupo-4-p1>