¿Quién termina hospitalizado por dengue?

Informe final · Proyectos 2 y 3 · Introducción a la ciencia de los datos

Grupo 4 · Universidad del Valle · Octubre 2026
Gustavo Restrepo Muñoz (2380618) · Santiago Velásquez Bedoya (2380378) · Nicolás Chaparro (2380530) · Santiago Hernández Aguado (2380367) · Felipe Ortiz Calan (2380642)

1. Contexto del dataset y pregunta de negocio

Se trabajó con las notificaciones de dengue del SIVIGILA (Instituto Nacional de Salud) entre 2022 y 2025, el mismo dataset del Proyecto 1: **581,071 registros y 20 columnas** con la semana y el año de notificación, la edad y su unidad de medida, sexo, departamento y municipio de ocurrencia, área (cabecera, centro poblado, rural), tipo de afiliación al sistema de salud, pertenencia étnica, estrato, grupos poblacionales (desplazados, migrantes, gestantes), tipo de caso y si el paciente fue hospitalizado (`PAC_HOS`).

En el Proyecto 1 la pregunta era la incidencia semanal por municipio. Al bajar a ese nivel la serie resultó demasiado rala (mediana de 2 casos por municipio y semana, y 35% de las celdas con un solo caso), así que se tomó la mejora que el P1 ya proponía: estudiar los factores asociados a la hospitalización. La pregunta de negocio quedó así:

> **¿Qué tan bien puede anticiparse, con la información disponible al notificar un caso, si el paciente será hospitalizado, y qué perfiles de paciente concentran la hospitalización?**

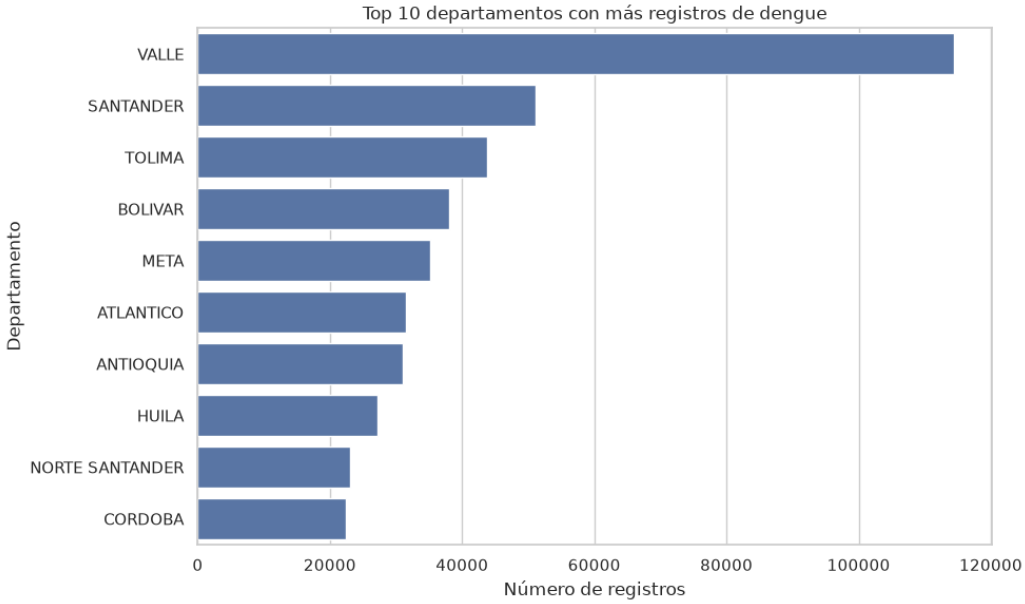
La respuesta sirve a una secretaría de salud para **priorizar seguimiento, camas y campañas**, no para reemplazar una decisión clínica. La variable objetivo es `PAC_HOS` (1 = hospitalizado, 38.4% de los casos; 0 = no, 61.6%), un problema de **clasificación binaria** con desbalance moderado.

2. Análisis exploratorio (Fase A)

El EDA (`fase_a_eda.ipynb`) incluyó histogramas, boxplots, correlaciones de Pearson y Spearman y gráficos de series, barras y proporciones. Los hallazgos más importantes fueron tres:

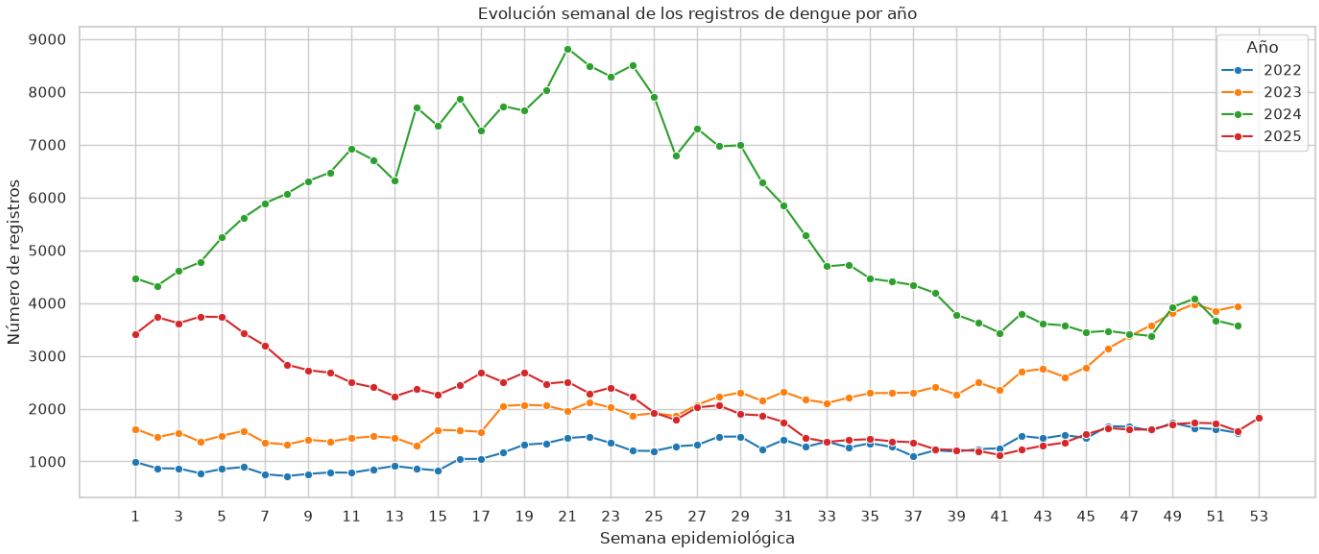
1. La carga está muy concentrada en el territorio. El Valle del Cauca acumula cerca de 115,000 registros, más del doble que Santander y Tolima. Repartir insumos por igual entre departamentos

desperdicia recursos; conviene focalizar pruebas, personal y control del vector en los cinco departamentos más afectados.



Los diez departamentos con más registros de dengue, 2022-2025.

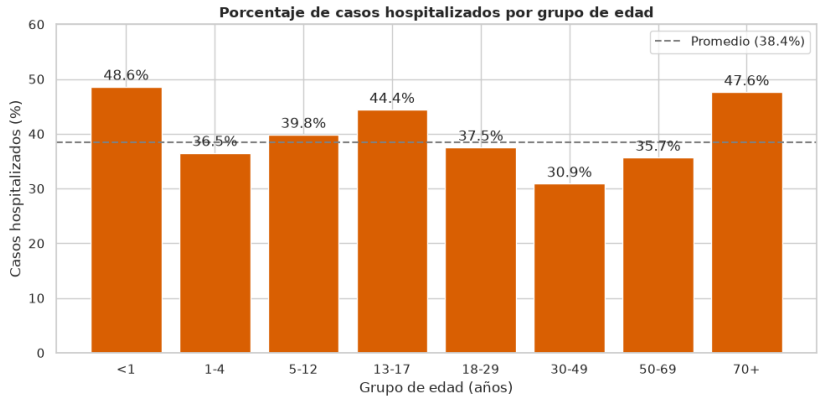
2. La epidemia no es estable entre años y tiene estacionalidad. 2024 fue un brote atípico (50% de todos los registros) con pico entre las semanas 15 y 25, y hay un repunte secundario al final del año. Las compras y la contratación de refuerzo deben planearse antes de mayo, no con promedios anuales. Además, la tasa de hospitalización registrada bajó de 53% en 2022 a cerca de 35% en 2024-2025: hay **deriva temporal**, que después se tuvo en cuenta en la evaluación de los modelos.



Registros semanales de dengue por año epidemiológico.

3. La hospitalización tiene forma de U según la edad. El contagio se concentra en escolares de 5 a 12 años (mediana de edad cercana a 17 años), pero la hospitalización es más alta en los extremos: 48.6% en menores de 1 año, 30.9% entre 30 y 49 años y 47.6% en mayores de 70. La correlación

lineal entre edad y hospitalización es casi nula ($r \approx -0.03$) justamente por esa forma de U. En una primera versión del EDA se había reportado un 70% de hospitalización en adultos; al revisar la codificación en la Fase B (`PAC_HOS` viene como 1 = Sí, 2 = No) se encontró que esa cifra correspondía a los no hospitalizados, y el hallazgo se corrigió.



Porcentaje de casos hospitalizados por grupo de edad.

3. Limpieza y normalización (Fase B)

El pipeline completo está en `fase_b_limpieza.ipynb` y produce `datos_limpios.parquet`. El principio rector fue **evitar el data leakage**: toda transformación que aprende de los datos se ajusta solo con el conjunto de entrenamiento.

Paso	Decisión	Justificación
Diagnóstico	Sin nulos reales, pero `estrato` vacío o «SIN DATO» (4.0%), edad en unidades mezcladas (8,580 en meses/días) y 21 edades > 100 años	Los nulos estaban disfrazados; detectarlos fue la base del resto
Limpieza determinística	`limpiar_basico`: estrato a nulo real, edad a años (`EDAD_ANIOS`), banderas 1/2 a 0/1	No calcula estadísticos, así que no puede filtrar información
Variables excluidas	`AJUSTE` y `nom_est_f_caso`	Se registran después de la notificación e incorporan el desenlace (47% vs 16% de hospitalización)
Duplicados (3.5%)	Se conservan	Sin ID de paciente pueden ser personas distintas; crecen con el tamaño del municipio
Outliers de edad (IQR)	22,816 adultos mayores se conservan; solo las 21 edades > 100 pasan a nulo	Son reales y tienen más hospitalización (46.2% vs 38.1%); eliminarlos sesgaría el modelo
Split	80/20 estratificado por `PAC_HOS`, `random_state=42`, **antes** de imputar	464,856 filas de train y 116,215 de test, ambas con 38.44% de hospitalizados
Imputación	Edad: **mediana**. Estrato: **KNN** (k = 5) frente a moda	KNN acertó 56.0% frente a 48.1% de la moda al ocultar el 10% de estratos

Paso	Decisión	Justificación
		conocidos
Sesgo	Edad con **Yeo-Johnson** (sesgo 1.25 → −0.02); municipio como log de sus casos en train	Yeo-Johnson admite ceros; 974 municipios eran demasiados para One-Hot
Codificación	**One-Hot** (`drop='first'`) para nominales; **ordinal** para estrato	Sexo, régimen o departamento no tienen orden; el estrato sí
Escalado	**RobustScaler** para edad, **Z-score** para log del municipio, **Min-Max** para estrato y año	La edad conserva extremos; el resto no

Se verificó que los escaladores vieron exactamente las 464,856 filas de train. El resultado tiene 581,071 filas, 63 variables de entrada, el objetivo y la columna `split`, sin nulos.

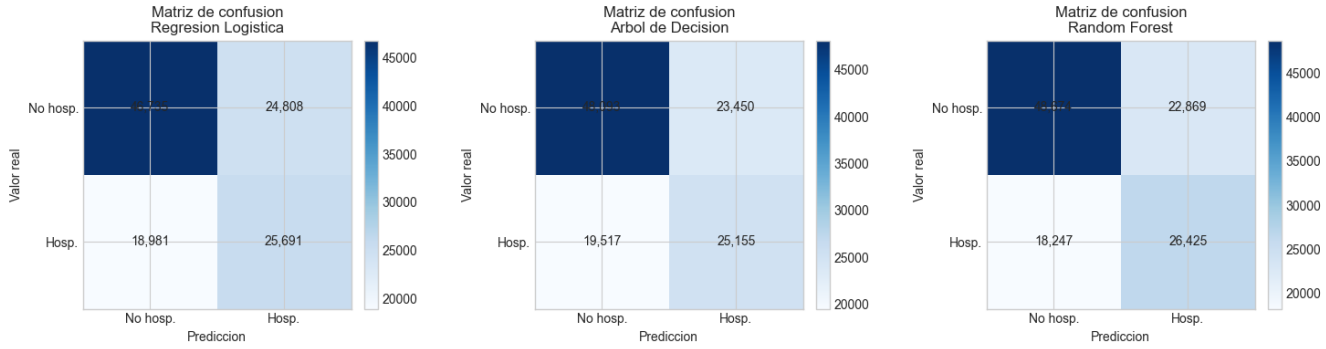
4. Modelos y comparación de desempeño (Fase C)

4.1 Modelos supervisados

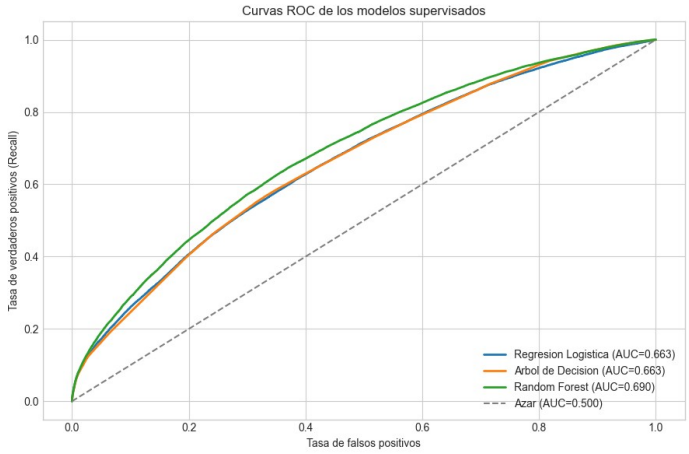
Se compararon tres clasificadores de la lista del curso: **Regresión Logística**, **Árbol de Decisión** y **Random Forest** (ensamble). KNN y SVM se descartaron por su costo con 465 mil filas. Cada modelo se entrenó dentro de un `Pipeline` (imputación, One-Hot y `StandardScaler` ajustados solo con train) a partir del consolidado, con la **misma partición de test** de la Fase B. Los hiperparámetros se buscaron con `GridSearchCV` (3 particiones, métrica ROC-AUC) solo sobre train, y se usó `class_weight="balanced"` para compensar el desbalance. Todas las métricas de la tabla se calcularon **en test**.

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	Tiempo de ajuste
Línea base (clase mayoritaria)	0.616	0.000	0.000	0.000	0.500	—
Regresión Logística	0.623	0.509	0.575	0.540	0.663	84 s
Árbol de Decisión	0.630	0.518	0.563	0.539	0.663	124 s
Random Forest	**0.646**	**0.536**	**0.592**	**0.562**	**0.690**	597 s

La línea base muestra por qué Accuracy no basta: predecir siempre «no hospitalizado» ya da 61.6% sin detectar un solo caso. Los tres modelos superan esa referencia, y Random Forest es el mejor en todas las métricas.



Matrices de confusión en test (umbral 0.5).



Curvas ROC de los tres modelos en test.

Controles adicionales. Sobre el modelo elegido se hicieron tres pruebas más:

- **Umbral:** elegido en una validación interna separada de train, el umbral 0.45 sube el Recall en test a **77.7%** (Precision 47.8%, F1 0.592). Para priorizar seguimiento es preferible perder menos hospitalizados aunque haya más falsas alarmas.
- **Validación temporal:** entrenado con 2022-2024 y evaluado en 2025, el ROC-AUC baja de 0.690 a **0.669**. La deriva existe, pero el modelo se sostiene.
- **Calibración:** el Brier score es 0.223. Por el `class_weight`, las probabilidades quedan infladas y sirven para ordenar casos, no como porcentaje exacto.

Las variables con más peso (importancia por permutación) fueron el departamento, el tipo de caso, el año, el régimen de salud y la edad. Son asociaciones, no causas.

4.2 Elección del modelo final

Se eligió **Random Forest**:

- **Precisión:** tiene el mayor ROC-AUC (0.690 frente a 0.663), Recall y F1, y conserva la ventaja en la validación temporal.
- **Velocidad:** es el más lento de entrenar, unas 7 veces más que la Regresión Logística (597 s frente a 84 s). Ese costo se paga una sola vez y predecir un caso nuevo es inmediato. Para un

uso de priorización que no exige reentrenar en tiempo real, la ganancia de discriminación lo justifica.

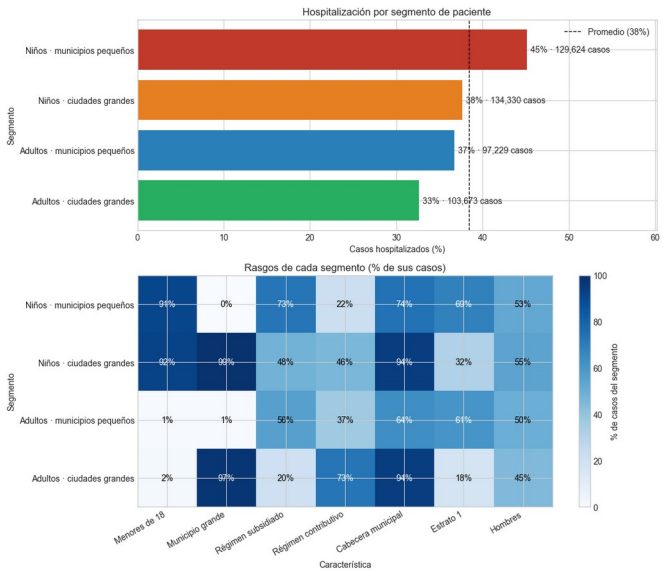
- **Interpretabilidad:** es menos interpretable que la Regresión Logística. Se compensó con importancia por permutación. Si se necesitara explicar cada caso o reentrenar con mucha frecuencia, la Regresión Logística sería la alternativa: pierde unos 3 puntos de AUC pero es más simple y rápida.

4.3 Modelo no supervisado: segmentación con K-Means

Para encontrar perfiles de paciente se aplicó **K-Means** sobre 19 variables sociodemográficas de `datos_limpios.parquet` (edad, estrato, sexo, régimen, área, etnia, grupos poblacionales y tamaño del municipio). Se excluyeron la hospitalización, que se usa después para describir los grupos, y el departamento, porque sus 29 columnas harían que los grupos fueran solo regiones. K-Means se ajustó solo con train.

Se probaron k = 2 a 10 con el método del codo, **Silhouette** y **Davies-Bouldin**. El Silhouette fue bajo en todos los casos (0.17-0.27): los pacientes forman un continuo, no grupos naturales. Se eligió **k = 4** porque ahí se dobla el codo y porque da perfiles accionables (**Silhouette 0.18, Davies-Bouldin 1.76**). Un clustering jerárquico de Ward llegó a una estructura parecida (ARI = 0.54) con peores métricas (Silhouette 0.13), así que se conservó K-Means.

Segmento	% de casos	Edad mediana	Rasgos principales	Hospitalizado
Niños y adolescentes · municipios pequeños	28%	10 años	73% subsidiado, 69% estrato 1	**45%**
Niños y adolescentes · ciudades grandes	29%	10 años	94% urbano, régimen mixto	38%
Adultos · municipios pequeños	21%	37 años	el más rural, 56% subsidiado	37%
Adultos · ciudades grandes	22%	34 años	94% urbano, 73% contributivo	33%



Hospitalización y rasgos de cada segmento (train).

Al evaluar el Random Forest dentro de cada segmento, con las variables de `datos_limpios.parquet` y el mismo test (ROC-AUC 0.715), el AUC es casi igual en los cuatro (0.70-0.72). Sin embargo, con umbral 0.5 detecta el 83% de los hospitalizados en niños de municipios pequeños y solo el 43% en adultos de ciudades grandes, porque cambia la tasa base de cada grupo. En la práctica, conviene un umbral más bajo para estos últimos.

5. Conclusiones y posibles mejoras

1. **La calidad de los datos fue la base.** Los nulos disfrazados, las edades en unidades mezcladas y las variables posteriores a la notificación habrían producido modelos con fuga de información si no se hubieran detectado. Hacer el split primero y ajustar todo con train fue lo que hizo honestos los resultados.
2. **El mejor modelo discrimina de forma moderada.** Random Forest alcanza un ROC-AUC de 0.69 (0.67 en 2025). Sirve para **priorizar** pacientes y recursos, no para decidir una hospitalización. Con umbral 0.45 detecta cerca de 78% de los hospitalizados.
3. **El perfil prioritario son los niños de municipios pequeños.** Se hospitalizan 45% de las veces, frente a 38% en promedio, y viven donde los recursos son más escasos. Conviene reforzar el seguimiento de signos de alarma en escuelas y centros de salud y planear camas pediátricas antes del pico de mayo y junio. En ciudades grandes el foco es la prevención y la atención ambulatoria.
4. **La epidemia cambia entre años.** El brote de 2024 y la caída de la hospitalización registrada obligan a validar el modelo con datos nuevos antes de usarlo.

Limitaciones. El objetivo es la hospitalización *registrada*, que también refleja capacidad de atención y criterios de remisión, no solo gravedad. Además, no hay denominadores de población, así que los resultados son conteos y no tasas.

Posibles mejoras.

- **Más datos:** población DANE por municipio para calcular tasas, y clima (lluvia y temperatura).
- **Más features:** signos de alarma y comorbilidades disponibles en la consulta.
- **Hiperparámetros y otros algoritmos:** Gradient Boosting, una búsqueda más amplia y calibración de probabilidades.
- **Validación:** partición temporal como práctica estándar.
- **Segmentación:** K-Prototypes o distancia de Gower, para que las variables categóricas pesen igual que las continuas.