PROYECTOS 2 Y 3 · GRUPO 4

¿Quién termina hospitalizado por dengue?

Análisis y modelos con 581,071 casos de dengue en Colombia (SIVIGILA, 2022-2025)

Gustavo Restrepo	2380618
Santiago Velásquez	2380378
Felipe Calán	2380642
Santiago Hernández	2380367
Nicolás Chaparro	2380530

La pregunta y los datos

- ¿Se puede anticipar, con lo que se registra al notificar un caso, si el paciente **será hospitalizado**?
- Datos: **581,071 casos** de dengue reportados al SIVIGILA entre 2022 y 2025.
- El **38.4%** de los casos fue hospitalizado y el 61.6% no.
- Uso esperado: **priorizar seguimiento y recursos**, no reemplazar la decisión del médico.

A Explorar los datos con gráficas

B Limpiar y preparar los datos

C Modelos que predicen la hospitalización

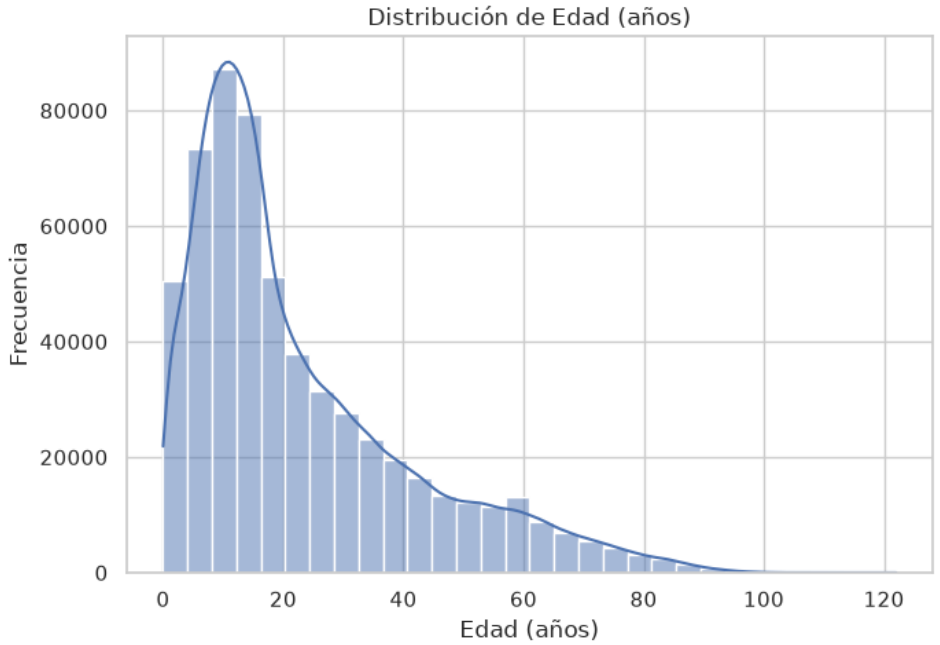
C Agrupar pacientes parecidos (segmentos)

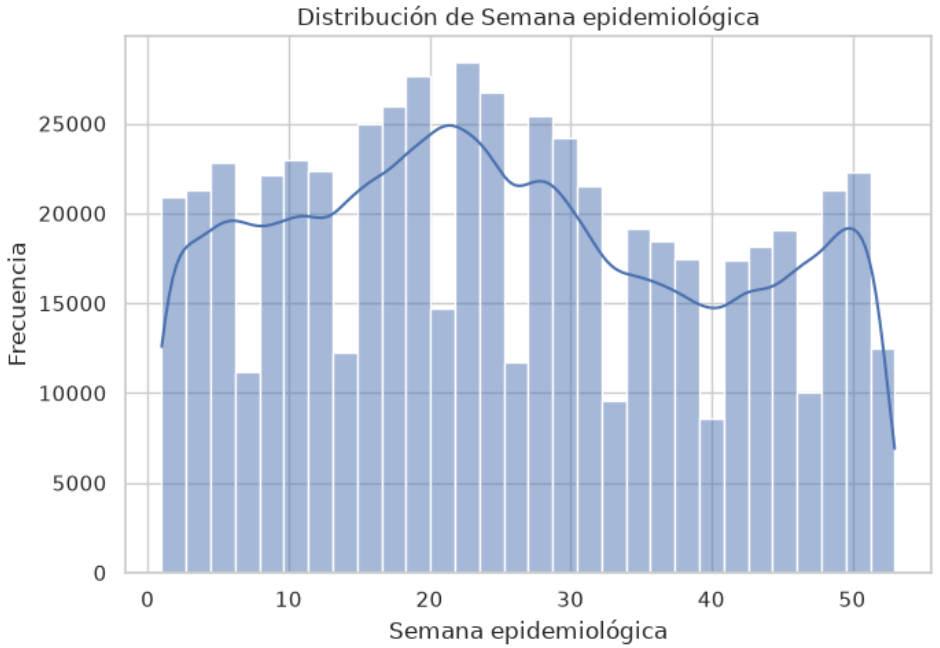
D Conclusiones y recomendaciones

FASE A · EXPLORACIÓN

¿A quién le da dengue y cuándo?

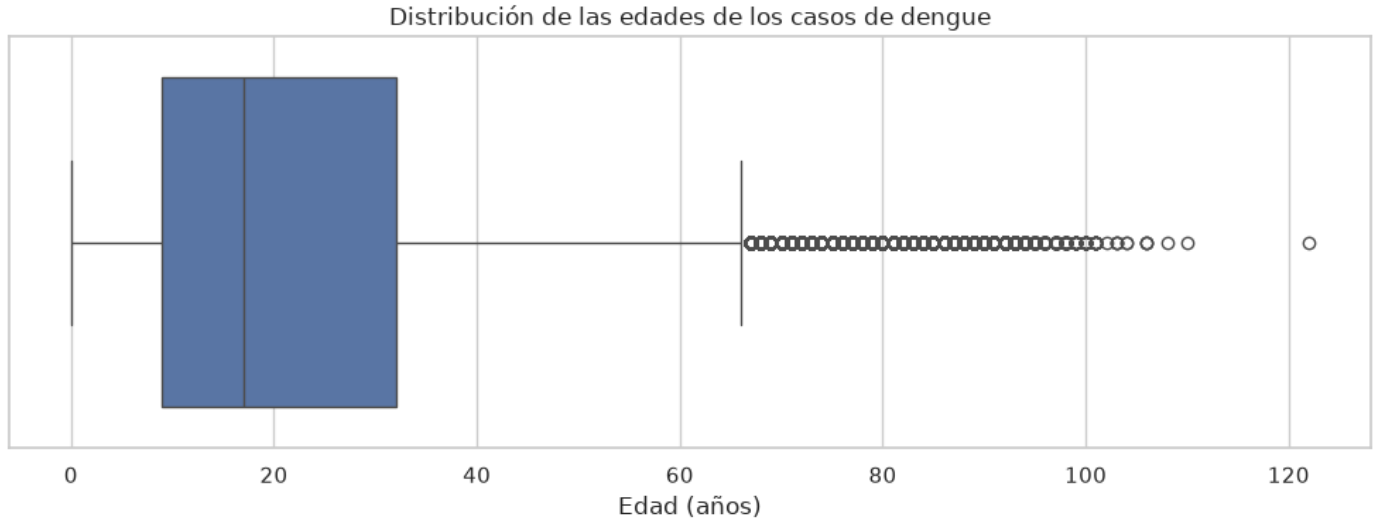
- La mayoría de casos son **niños y jóvenes**: el pico está entre **5 y 12 años**.
- Dos temporadas altas al año: **semanas 20-25** (mayo-junio) y **48-52** (noviembre-diciembre).
- Insumos y personal deberían estar listos **antes de la semana 18**.





Distribución de la edad

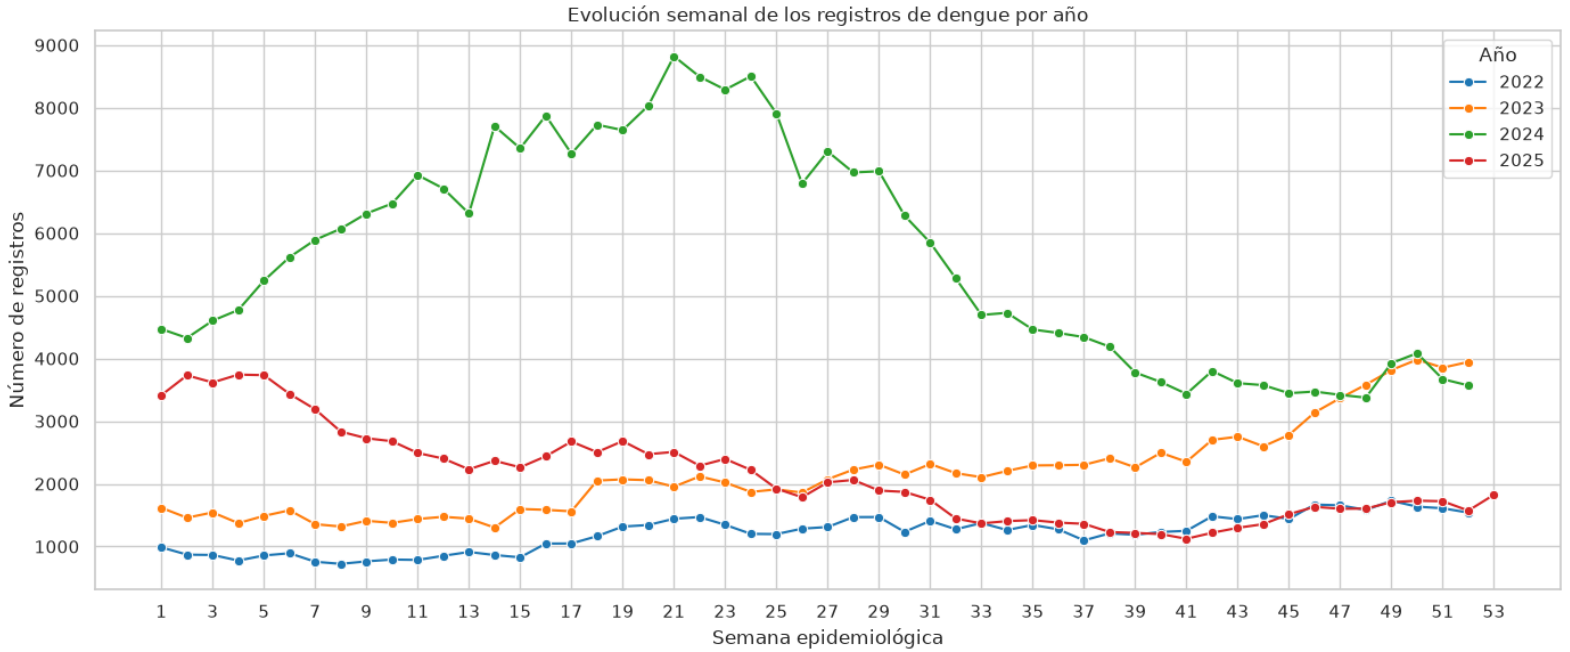
- La mitad de los casos tiene menos de **17 años**.
- El 50% central está entre **9 y 32 años**.
- Los mayores de 65 aparecen como atípicos, pero son **casos reales**.
- Edades de más de 100 años (hasta 122) son **errores de digitación**.



FASE A · EXPLORACIÓN

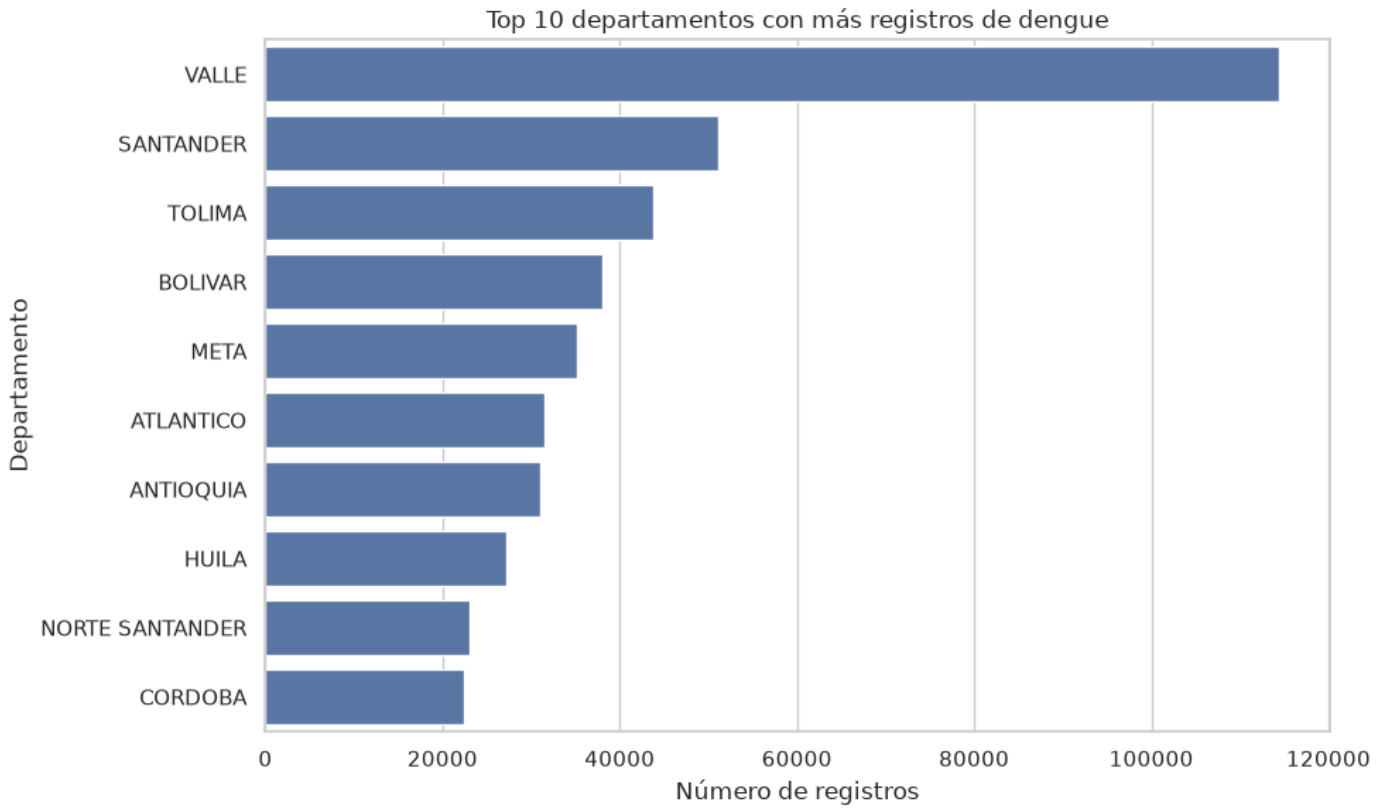
2024 fue un año de brote

- En 2024 se llegó a cerca de **8,800 casos por semana** (semanas 15-25).
- 2022 fue un año bajo; 2025 se fue estabilizando.
- El aumento empezó a finales de 2023: hacen falta **alertas tempranas**, no promedios de años anteriores.



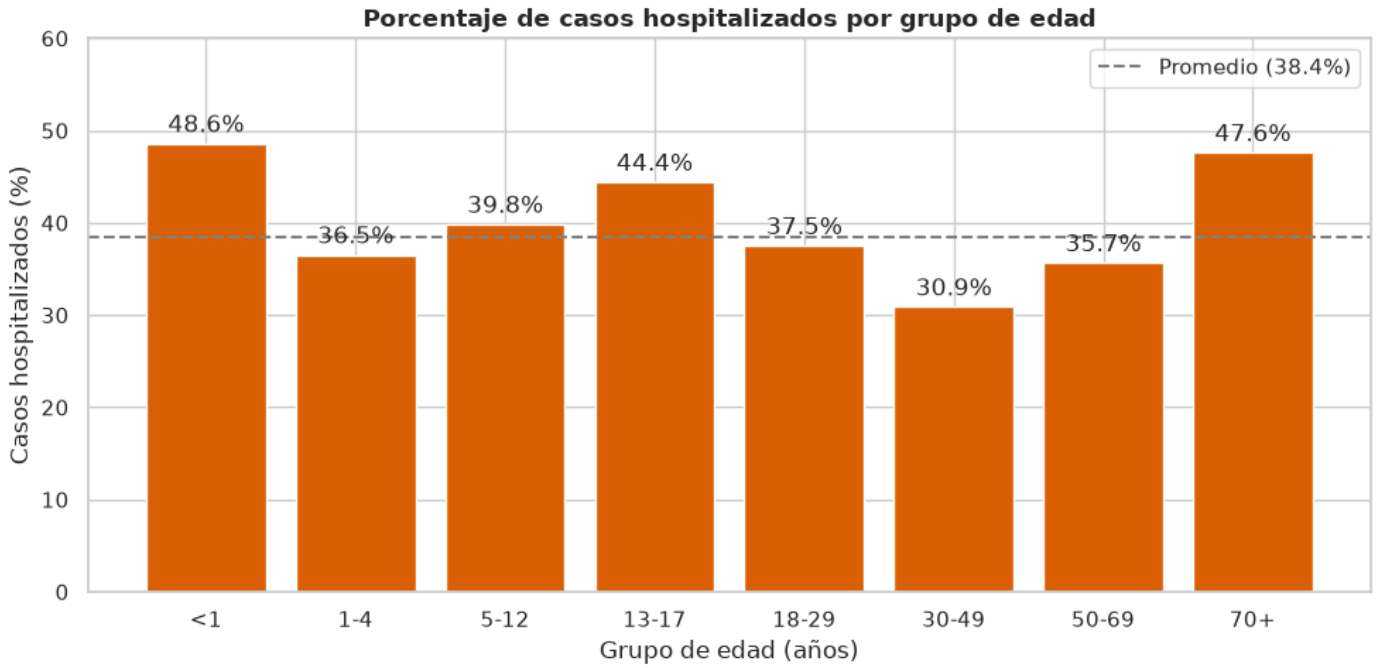
Pocos departamentos concentran los casos

- **Valle** lidera con cerca de **115,000 casos**, más del doble que Santander y Tolima.
- El dengue no se reparte igual en el país: hay **focos regionales**.
- Presupuesto y control del mosquito deberían enfocarse en esas regiones.



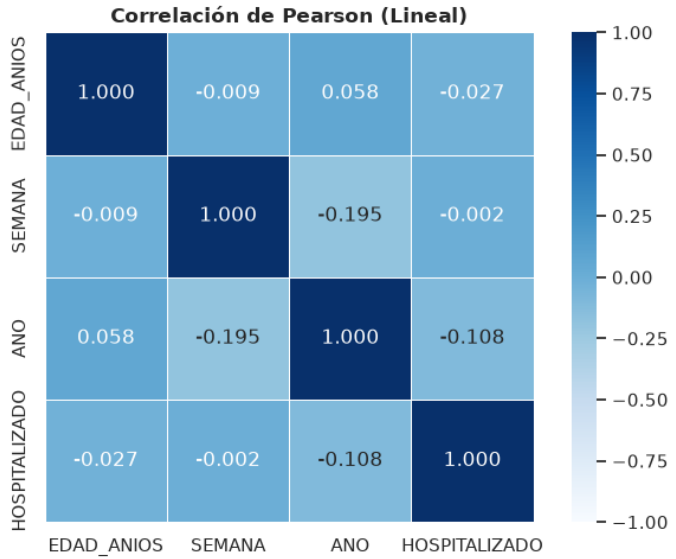
La hospitalización tiene forma de U según la edad

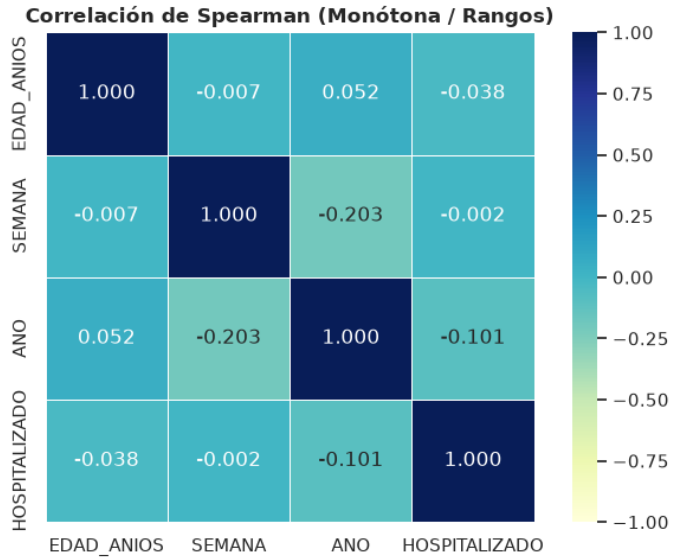
- Se hospitalizan más los **bebés menores de 1 año (48.6%)** y los **mayores de 70 (47.6%)**.
- Los adultos de 30 a 49 años son los que menos (30.9%). Promedio: 38.4%.
- Los niños de 5 a 12 no son los de más riesgo, pero sí los de **más casos (160 mil)**.



Ninguna variable sola explica la hospitalización

- Las correlaciones con la hospitalización son **casi cero** (edad −0.03, semana ≈ 0).
- Solo el año pesa un poco (−0.11): **la hospitalización bajó** en los años recientes.
- Ojo: casi cero no significa que la edad no importe; su efecto es en **U**, no en línea recta.
- Por eso los modelos **combinan varias variables**.





FASE B · LIMPIEZA

Qué problemas tenían los datos y qué hicimos

Problema	Cuántos	Decisión
Estrato vacío o "SIN DATO"	23,504 (4%)	Se rellenó con los casos más parecidos (KNN)
Edad en meses, días u horas	8,580	Se pasó todo a años
Edades de más de 100 años	21	Se trataron como dato faltante
Filas repetidas	20,454 (3.5%)	Se conservaron: pueden ser pacientes distintos con el mismo perfil
Mayores de 67 años (atípicos)	22,816 (3.9%)	Se conservaron: son reales y se hospitalizan más (46%)
Datos que se llenan después del caso	AJUSTE, estado final	Se quitaron: "adelantan" el resultado

FASE B · PREPARACIÓN

Cómo preparamos los datos sin hacer trampa

- Primero se separó **80% para entrenar** y **20% para probar** (misma proporción de hospitalizados).
- Todo lo que "aprende" de los datos se calculó **solo con el 80%** de entrenamiento.
- Se comprobó que el conjunto de prueba **nunca se usó** antes de la evaluación final.
- Resultado: archivo **datos_limpios.parquet** con 63 columnas y sin datos faltantes.

Rellenar el estrato faltante

Método	Acierta	Error medio
Usar siempre el más común	48.1%	0.74
Casos más parecidos (KNN)	**56.0%**	**0.53**

- Edad y tamaño del municipio estaban muy sesgados: se **transformaron** para equilibrarlos.
- La semana se trató como un **ciclo** (la 52 queda junto a la 1).

FASE C · MODELOS

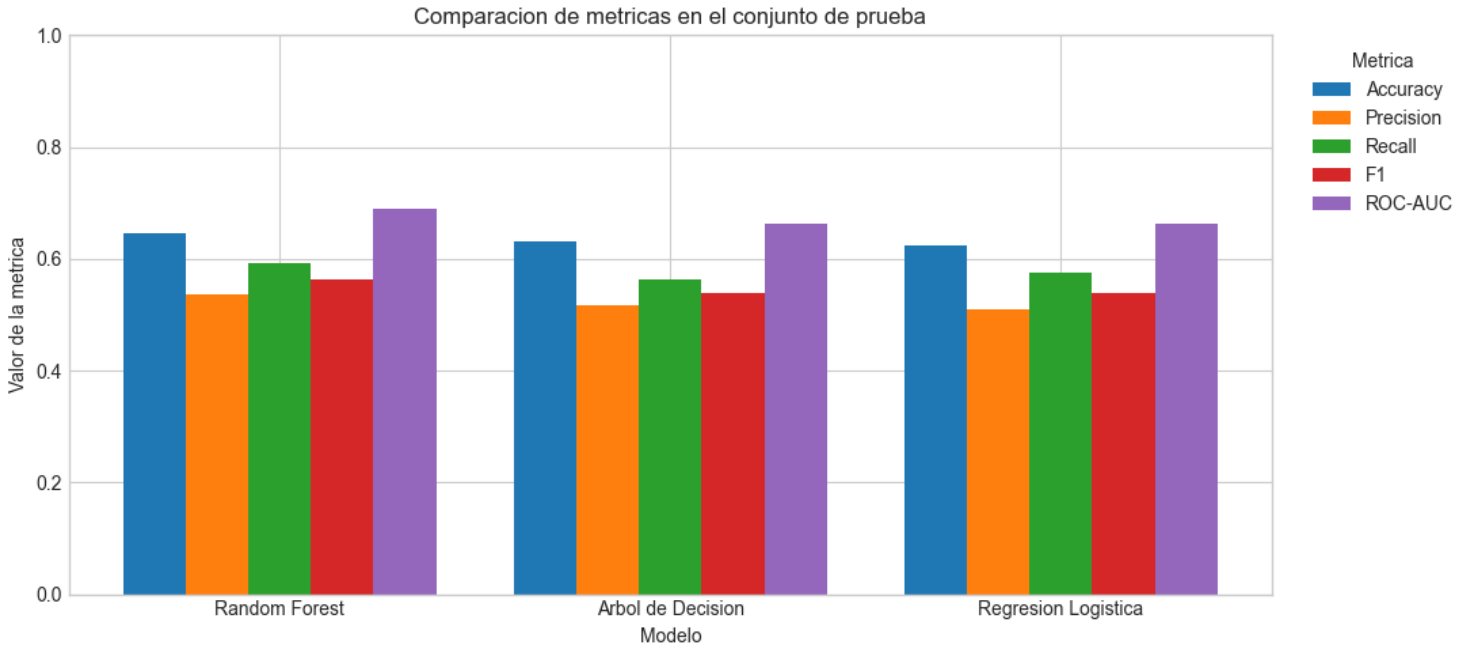
Tres modelos para predecir la hospitalización

Modelo	Aciertos	Detecta hosp.	AUC	Tiempo
Random Forest	**64.6%**	**59.2%**	**0.690**	**597 s**
Árbol de Decisión	63.0%	56.3%	0.663	124 s
Regresión Logística	62.3%	57.5%	0.663	84 s
Adivinar siempre "no"	61.6%	0%	0.500	—

- **AUC**: qué tan bien separa hospitalizados de no hospitalizados (0.5 = azar, 1 = perfecto).
- Ganó **Random Forest** en casi todo, aunque tarda **7 veces más** en entrenar (se entrena una sola vez).
- Regresión Logística queda como opción rápida y **fácil de explicar**.

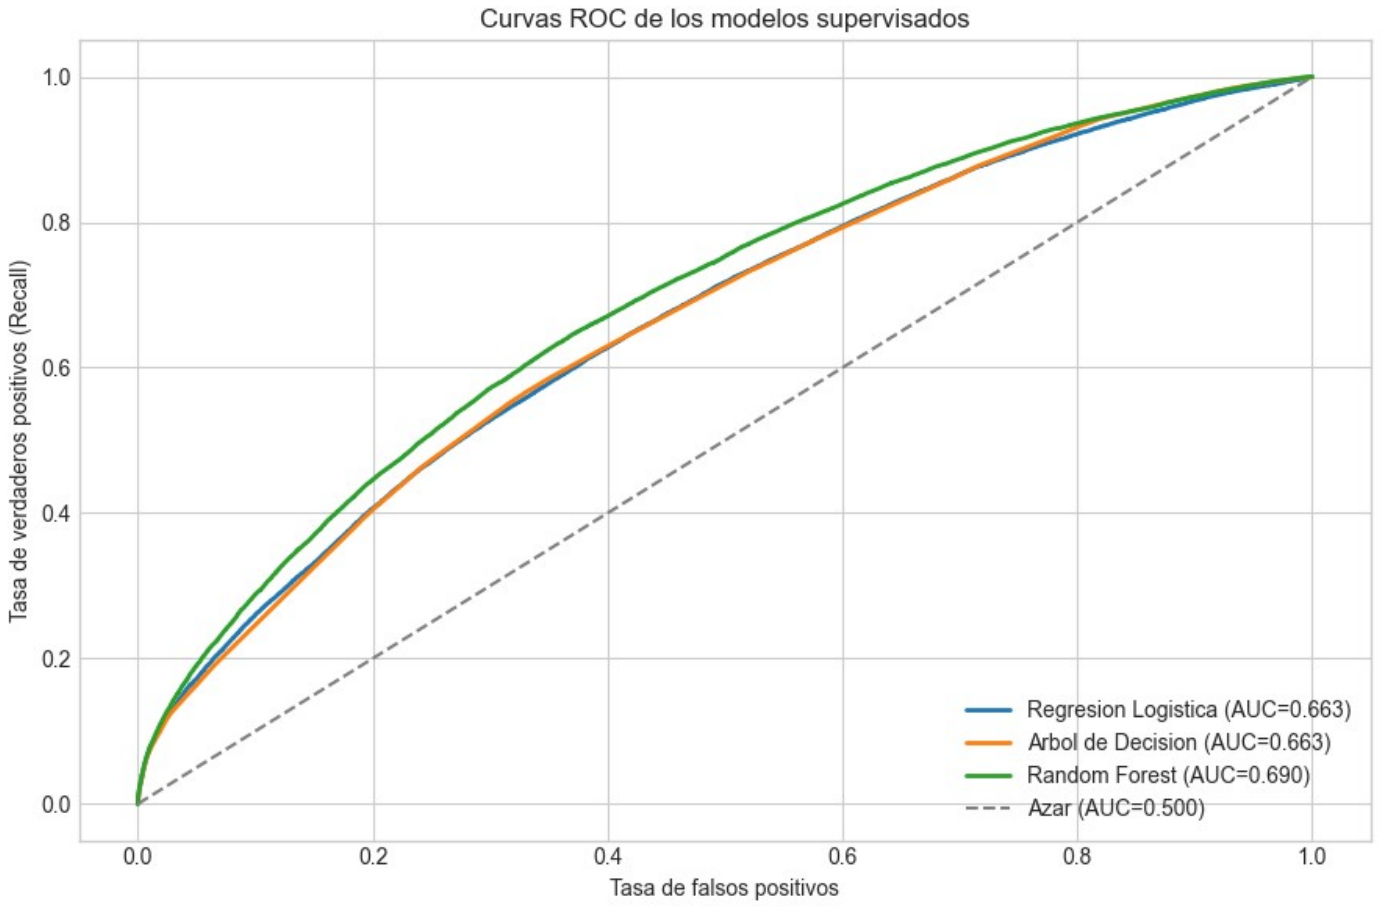
Comparación de las métricas

- **Precision**: de las alertas que da el modelo, cuántas eran hospitalizaciones reales.
- **Recall**: de los hospitalizados reales, cuántos detecta el modelo.
- No hay ganador absoluto: depende de qué error cuesta más. Random Forest es el más parejo.



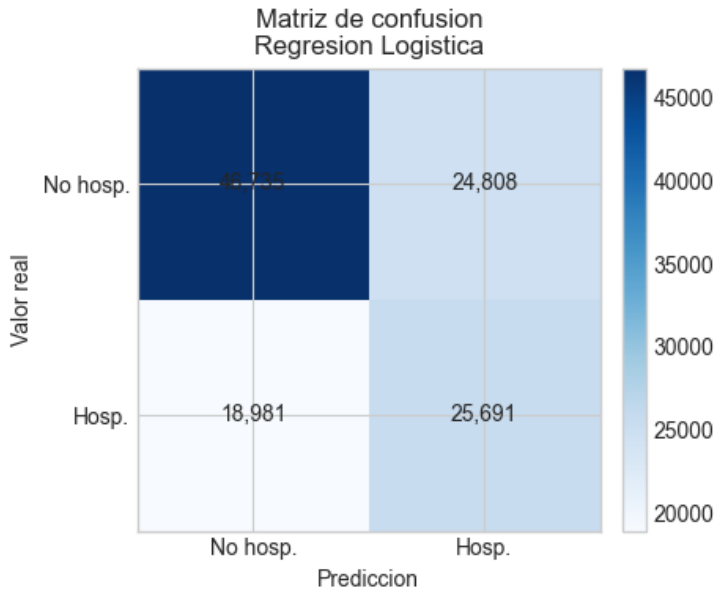
Curvas ROC: los tres superan al azar

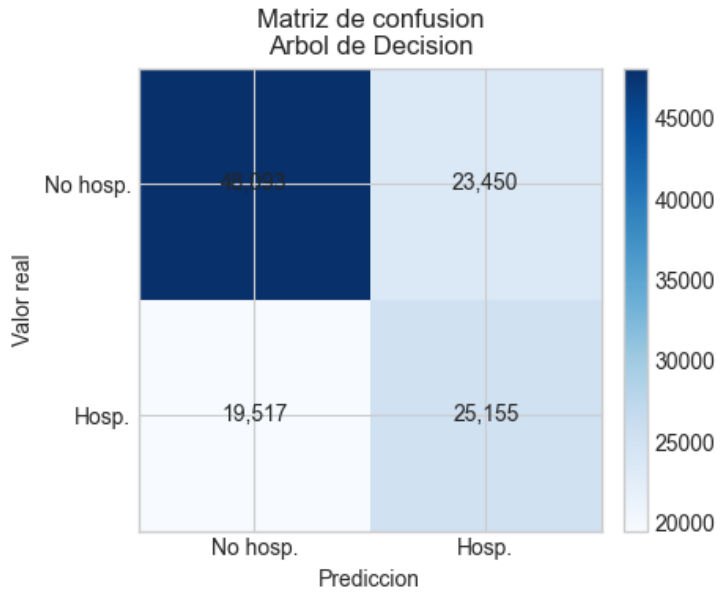
- Mientras más arriba está la curva, **mejor separa** los dos grupos.
- Random Forest (verde) queda por encima: **AUC 0.690**.
- Un AUC cercano a 0.70 es **útil pero moderado**: sirve para priorizar, no para decidir.

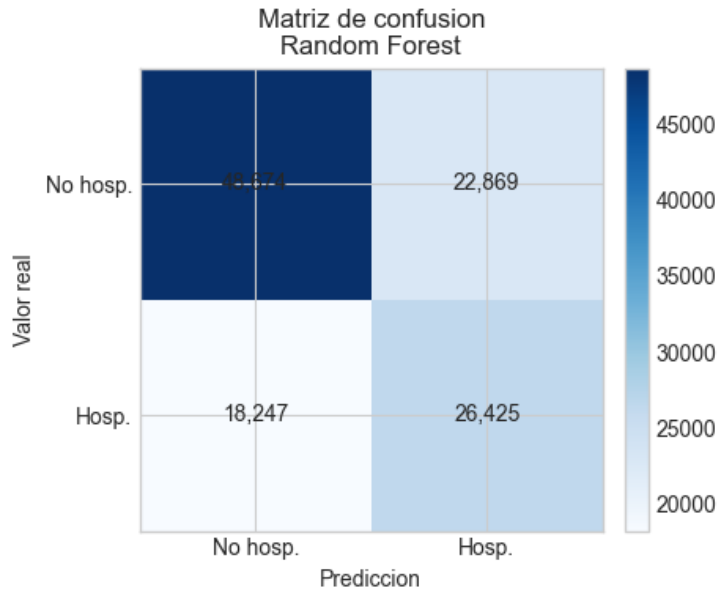


Dónde acierta y dónde se equivoca cada modelo

- Random Forest detecta **26,425** de 44,672 hospitalizados de prueba, el que más.
- El error más delicado: hospitalizados que el modelo dice que no (**18,247** en Random Forest).

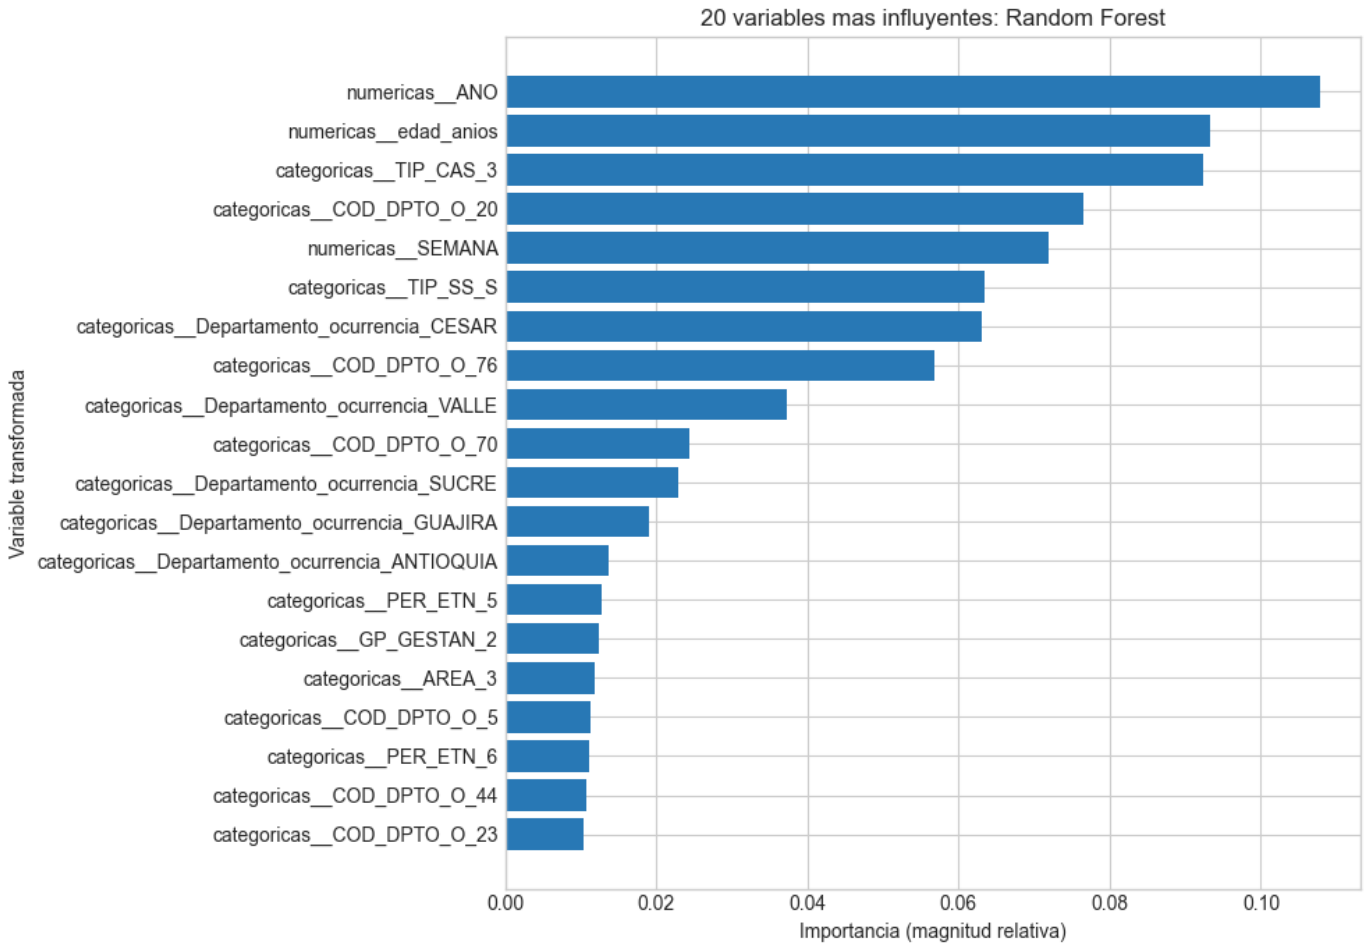






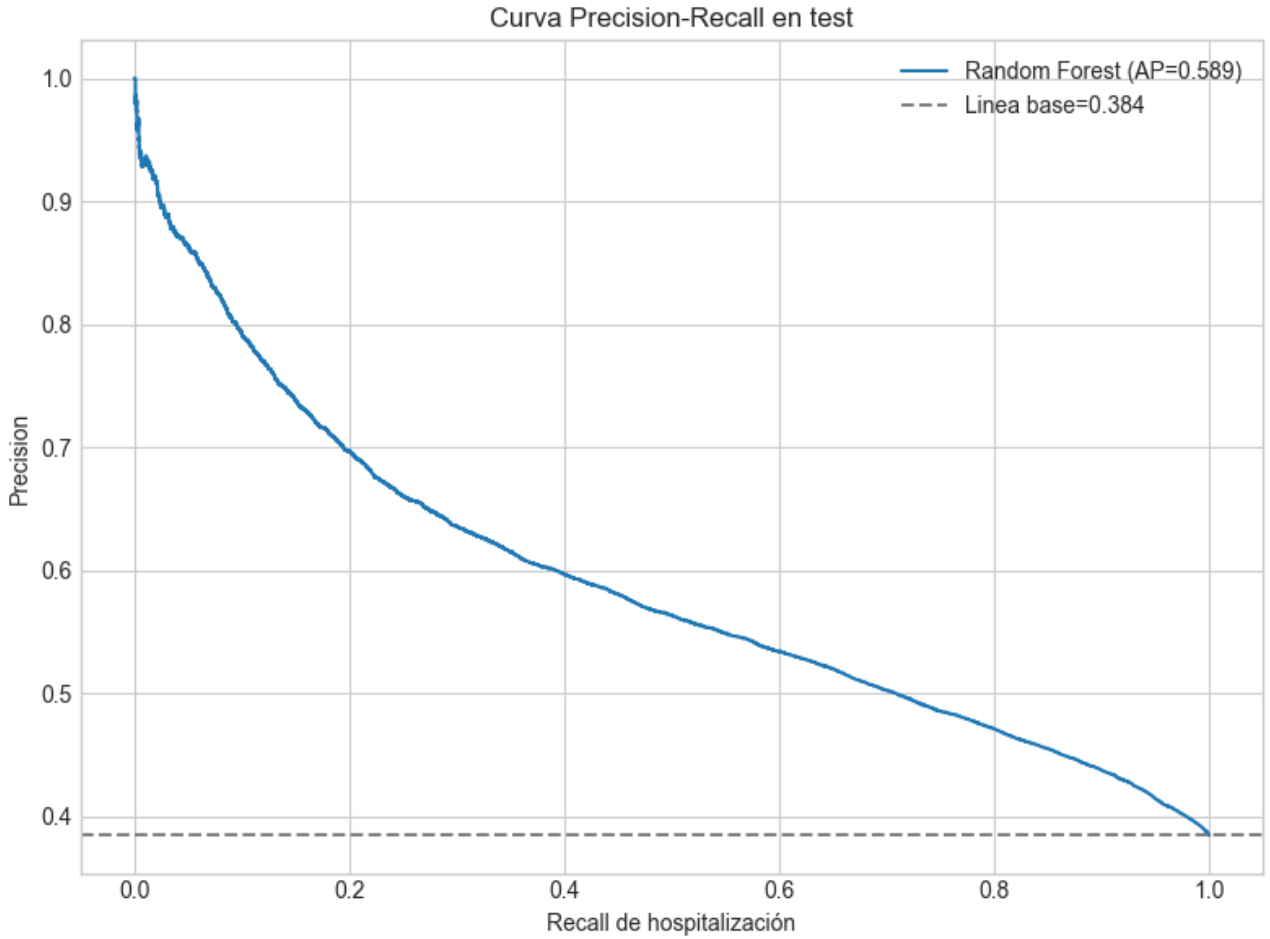
¿En qué se fija el modelo?

- Lo que más usa: **año**, **edad**, **tipo de caso al notificar** y **departamento** (Cesar, Valle).
- Al "desordenar" cada variable, la que más empeora el modelo es el **departamento**.
- Son señales que ayudan a predecir, **no causas** de la hospitalización.



Ajustar el umbral para no perder pacientes

- Por defecto el modelo alerta si la probabilidad pasa de 0.5.
- Bajando el umbral a **0.45** detecta el **78%** de los hospitalizados (antes 59%).
- A cambio, solo el **48%** de las alertas son hospitalizaciones reales.
- El umbral se eligió sin mirar los datos de prueba.

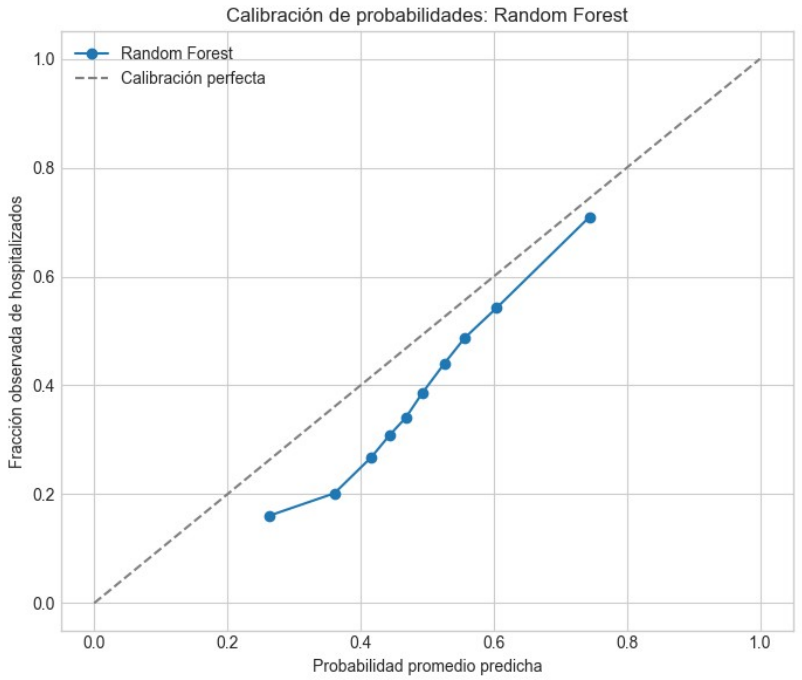


¿Funciona con datos del futuro?

Hospitalización registrada por año

Año	Casos	Hospitalizados
2022	63,076	52.8%
2023	113,314	44.6%
2024	292,384	33.6%
2025	112,297	36.8%

- Entrenando con 2022-2024 y probando en **2025**, el AUC baja de **0.690 a 0.669**.
- Los datos cambian con los años: el modelo hay que **actualizarlo**.

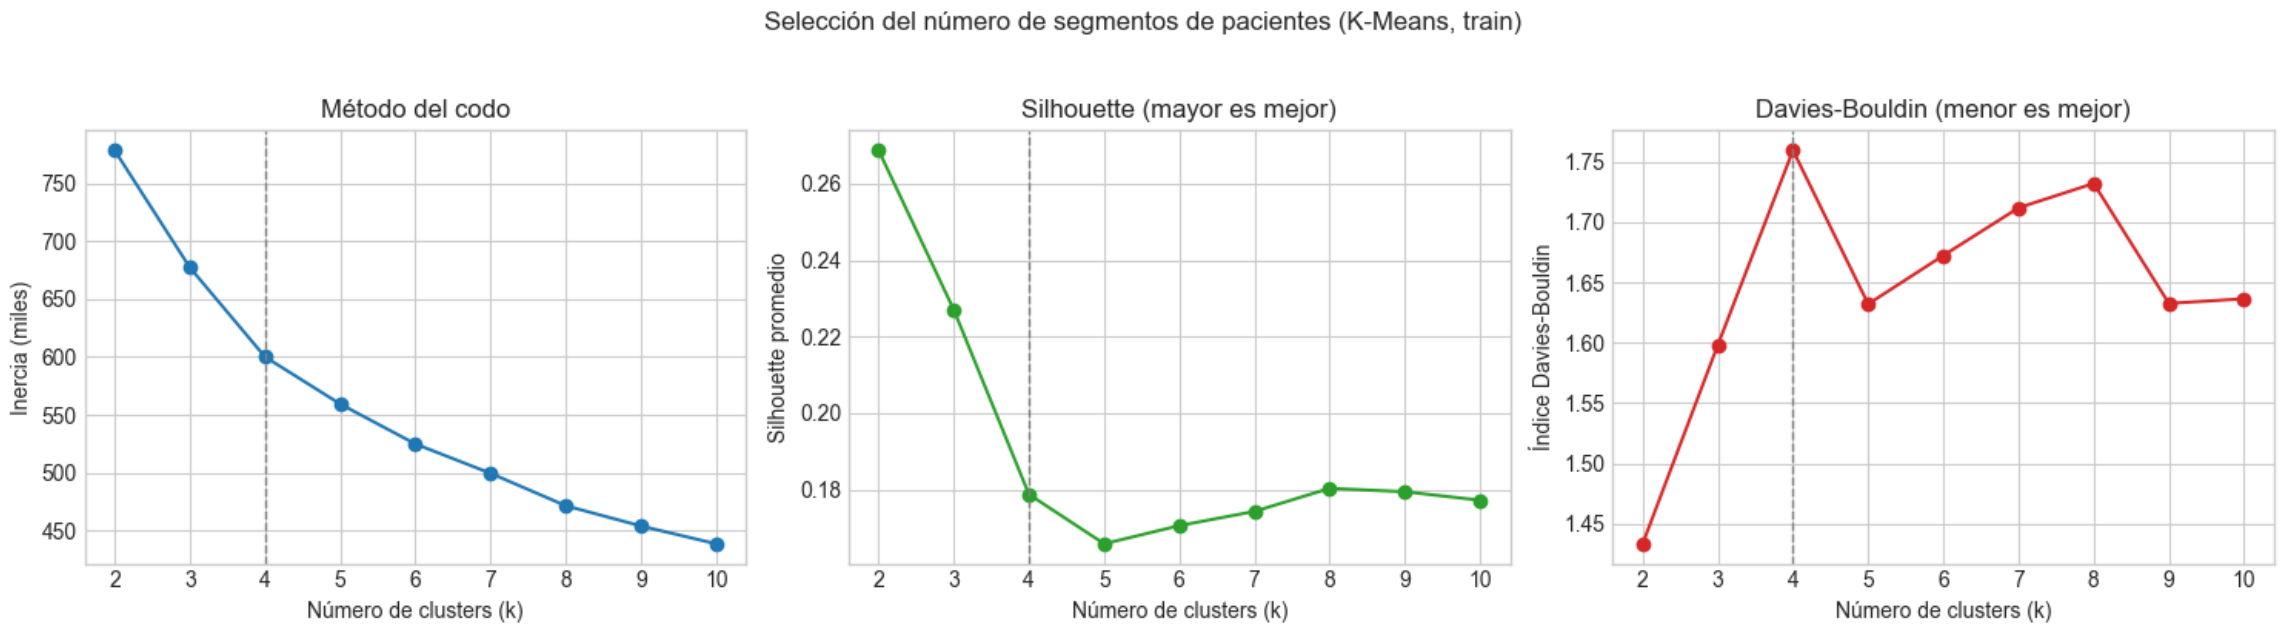


Las probabilidades del modelo salen **algo infladas**.

Sirven para **ordenar** pacientes, no como porcentaje exacto.

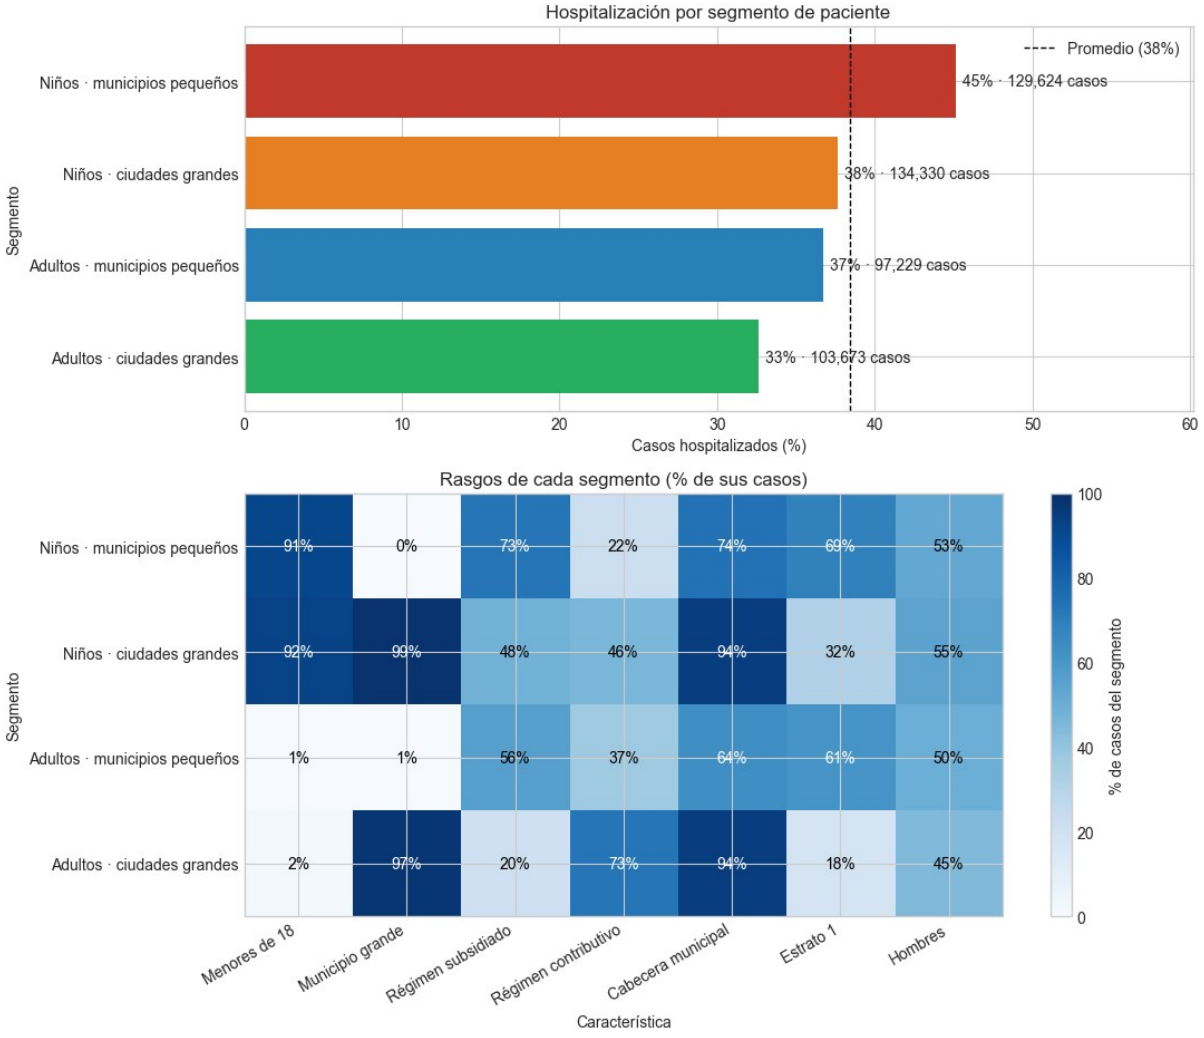
Agrupar pacientes parecidos: ¿cuántos grupos?

- Se usó **K-Means** con edad, estrato, régimen de salud, zona y tamaño del municipio.
- Se eligieron **4 grupos**: desde ahí agregar más grupos casi no mejora (método del codo).
- Los grupos no están muy separados: son **cortes de un continuo**, útiles para planear.



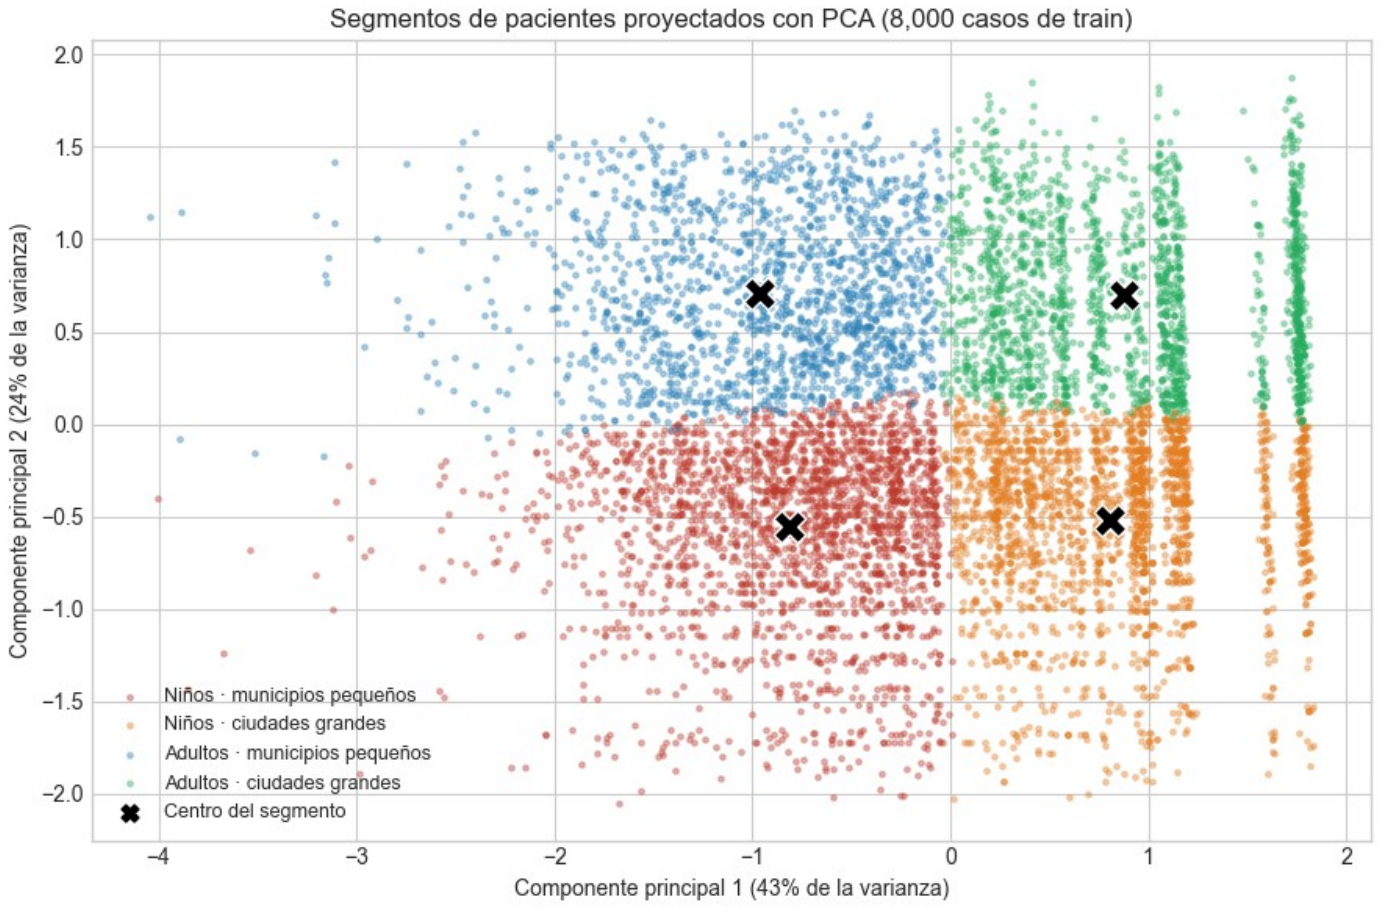
Los 4 segmentos de pacientes

- Se forman por dos cosas: **edad** (niños o adultos) y **tamaño del municipio**.
- **Niños de municipios pequeños** (28% de casos): se hospitalizan el **45%**, el grupo prioritario.
- Niños de ciudades grandes: 38%. Adultos de municipios pequeños: 37%.
- **Adultos de ciudades grandes**: el que menos, **33%**.
- En municipios pequeños predominan el régimen subsidiado, el estrato 1 y la zona rural.



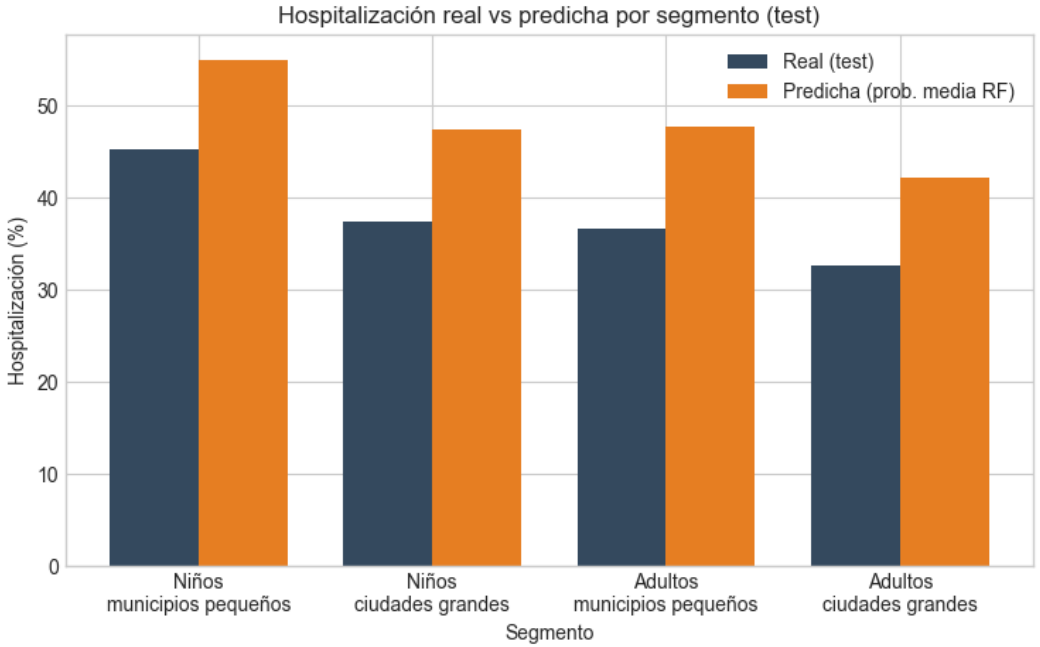
Los grupos vistos en un mapa de 2 dimensiones

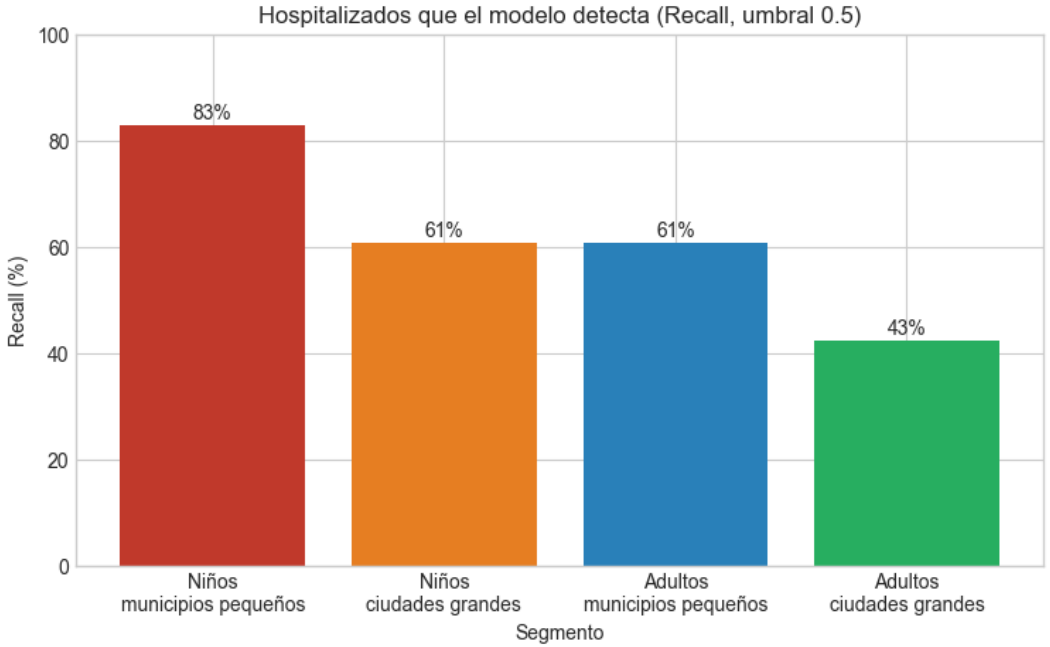
- Con 2 ejes se resume el **67%** de la información: **tamaño del municipio** y **edad**.
- Los 4 grupos aparecen como **cuadrantes** de un mismo plano.
- Otro método (jerárquico de Ward) encuentra una estructura parecida (coincidencia **0.54**).
- K-Means se queda: mejores métricas y funciona con los 581 mil casos.



El modelo según cada segmento

- El modelo **ordena bien** los grupos: predice más donde más se hospitaliza (barras naranjas, ~10 puntos arriba).
- Detecta el **83%** de hospitalizados en niños de municipios pequeños, pero solo el **43%** en adultos de ciudades grandes.
- Recomendación: usar un **umbral más bajo** para los adultos de ciudades grandes.





CONCLUSIONES

Lo más importante

581 mil

casos analizados (2022-2025)

38.4%

fue hospitalizado

0.69-0.71

AUC del mejor modelo (Random Forest)

45%

hospitalización en niños de municipios pequeños

- El dengue golpea más a **niños y jóvenes**, en **pocos departamentos** (Valle) y con **brotes** como el de 2024.
- Se hospitalizan más los **bebés y mayores de 70**; la hospitalización registrada **bajó** de 53% (2022) a ~35%.
- El modelo **no sirve para decidir un caso**, pero sí para **orientar recursos** hacia los grupos de mayor riesgo.

Recomendaciones y mejoras

Para salud pública

- Reforzar seguimiento y camas pediátricas en **municipios pequeños** antes de la temporada alta.
- En ciudades grandes: **prevención** (control del mosquito) y atención ambulatoria.
- Ajustar el umbral de alerta **por segmento**.

Para mejorar el modelo

- Agregar **población DANE** (tasas reales), **clima** y **datos clínicos** (signos de alarma).
- Validar siempre con **años nuevos** por los cambios entre años.
- Probar otros modelos (Gradient Boosting) y **calibrar** las probabilidades.
- Segmentar dando el mismo peso a sexo, etnia y grupos poblacionales.

Gracias

¿Preguntas?