INTRODUCCIÓN A LA CIENCIA DE DATOS · PROYECTOS 2 Y 3

¿Quién termina hospitalizado por dengue?

Exploración, limpieza, modelos predictivos y segmentación de 581,071 casos notificados al SIVIGILA entre 2022 y 2025

Grupo 4 · Universidad del Valle

Octubre 2026

CONTEXTO

Pregunta de negocio: ¿qué pacientes con dengue terminan hospitalizados?

581,071

casos notificados al SIVIGILA, 2022–2025, con 20 variables por caso

38.4%

fueron hospitalizados: la variable objetivo **PAC_HOS** (sí / no)

80 / 20

entrenamiento y prueba, estratificado y con semilla fija (42)

Es un problema de **clasificación**. Descartamos predecir casos semanales por municipio (la idea del P1) porque esa serie es muy rala: la mediana es de 2 casos por municipio y semana.

FASE A · ANÁLISIS EXPLORATORIO

Tres hallazgos del EDA

1 · Territorio

114,398

casos en el Valle del Cauca, más del doble que Santander (51,132) y Tolima (43,806). La carga se concentra en pocos departamentos.

2 · Edad

17 años

es la edad mediana; el pico está entre los 5 y los 12 años. El dengue golpea sobre todo a escolares.

3 · Tiempo

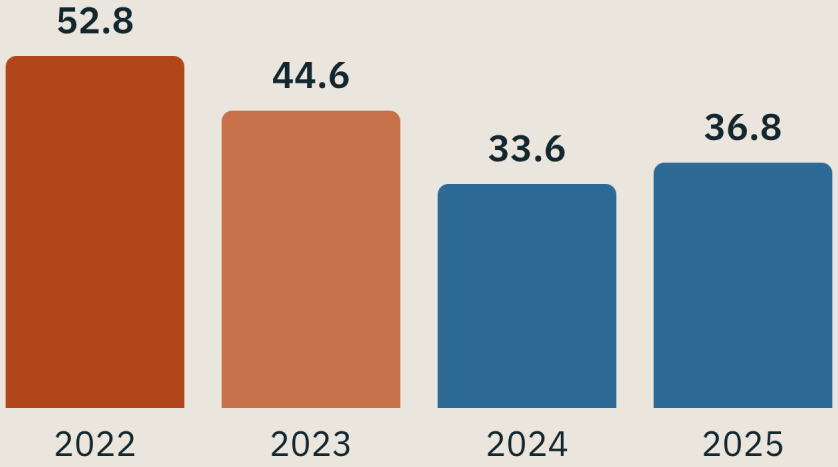
≈ 8,800

casos por semana en el pico de 2024 (semanas 15 a 25). Ese año aportó el 50% de todos los registros: fue un brote atípico.

FASE A · HOSPITALIZACIÓN

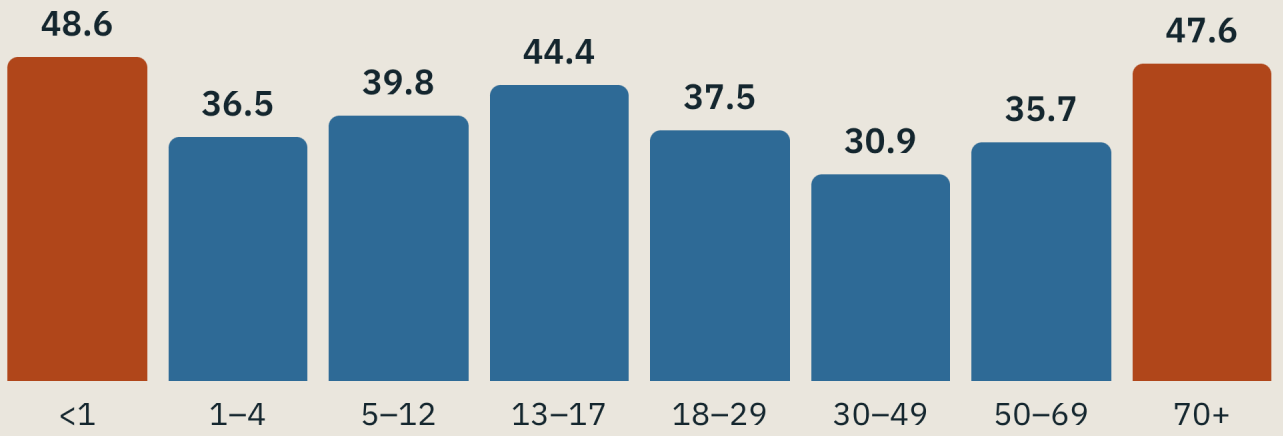
La hospitalización cambia con el año y con la edad

Hospitalizados por año (%)



Deriva temporal: de 53% a ~35%. Un modelo entrenado con años viejos sobreestima el presente.

Hospitalizados por grupo de edad (%)



Forma de U: los extremos de la vida (bebés y mayores de 70) se hospitalizan más.

FASE B · CALIDAD DE DATOS

Casi no había nulos: había datos disfrazados

Problema	Registros	Decisión y por qué
Estrato en blanco o «SIN DATO»	23,504 (4%)	Nulo real → imputar con KNN después del split
Edad en meses, días u horas	8,580	Convertir todo a años con UNI_MED
Edad mayor de 100 años	21	Error de digitación → mediana de train
Adultos mayores (outliers IQR)	67–100 años	Conservar: son reales y de alto riesgo
Filas duplicadas exactas	20,454 (3.5%)	Conservar: sin ID pueden ser pacientes distintos
AJUSTE y clasificación final	2 variables	Excluir: se conocen después de notificar (fuga de información)

FASE B · PIPELINE SIN FUGA DE INFORMACIÓN

Primero se divide; todo lo demás se aprende solo con train

1 · Split

80/20 estratificado por PAC_HOS, semilla 42

2 · Imputar

Estrato con KNN: acierta 56% frente a 48% de la moda

3 · Transformar

Edad con Yeo-Johnson: sesgo de 1.25 a −0.02

4 · Codificar

One-Hot para nominales; ordinal para estrato 1–6

5 · Escalar

Robust (edad), Z-score (municipio), Min-Max (estrato, año)

Verificación: los escaladores vieron **464,856 filas**, exactamente las de train. Resultado: **datos_limpios.parquet** con 63 variables, el objetivo y la columna split.

FASE C · MODELOS SUPERVISADOS

Random Forest gana en todas las métricas, por poco

Modelo (test)	Accuracy	Precision	Recall	F1	ROC-AUC
Random Forest (elegido)	0.646	0.536	0.592	0.562	0.690
Árbol de decisión	0.630	0.518	0.563	0.539	0.663
Regresión logística	0.623	0.509	0.575	0.540	0.663
Línea base: «nadie se hospitaliza»	0.616	0.000	0.000	0.000	0.500

Hiperparámetros con GridSearchCV (3 folds, solo train) y **class_weight** para el desbalance. La línea base muestra que la Accuracy sola engaña: predecir siempre «no» ya da 62%.

FASE C · USO DEL MODELO

Bajando el umbral a 0.45 detectamos 78% de los hospitalizados

Recall con umbral 0.45

77.7%

frente a 59% con 0.5. A cambio, la precisión baja a 48%: más falsas alarmas.

Prueba con el futuro

0.669

de AUC al entrenar hasta 2024 y evaluar en 2025 (0.690 con split aleatorio). La deriva cuesta poco.

Lo que más pesa

Departamento, tipo de caso, año, régimen de salud y edad

(importancia por permutación)

Con AUC ≈ 0.70 la discriminación es **moderada**: sirve para priorizar seguimiento, no para decidir una hospitalización individual.

FASE C · SEGMENTACIÓN CON K-MEANS (K = 4)

Cuatro perfiles de paciente: edad × tamaño del municipio

45%

Niños · municipios pequeños

28% de los casos · 73% subsidiado · 69% estrato 1

38%

Niños · ciudades grandes

29% de los casos · 94% urbano · régimen mixto

37%

Adultos · municipios pequeños

21% de los casos · el más rural · 61% estrato 1

33%

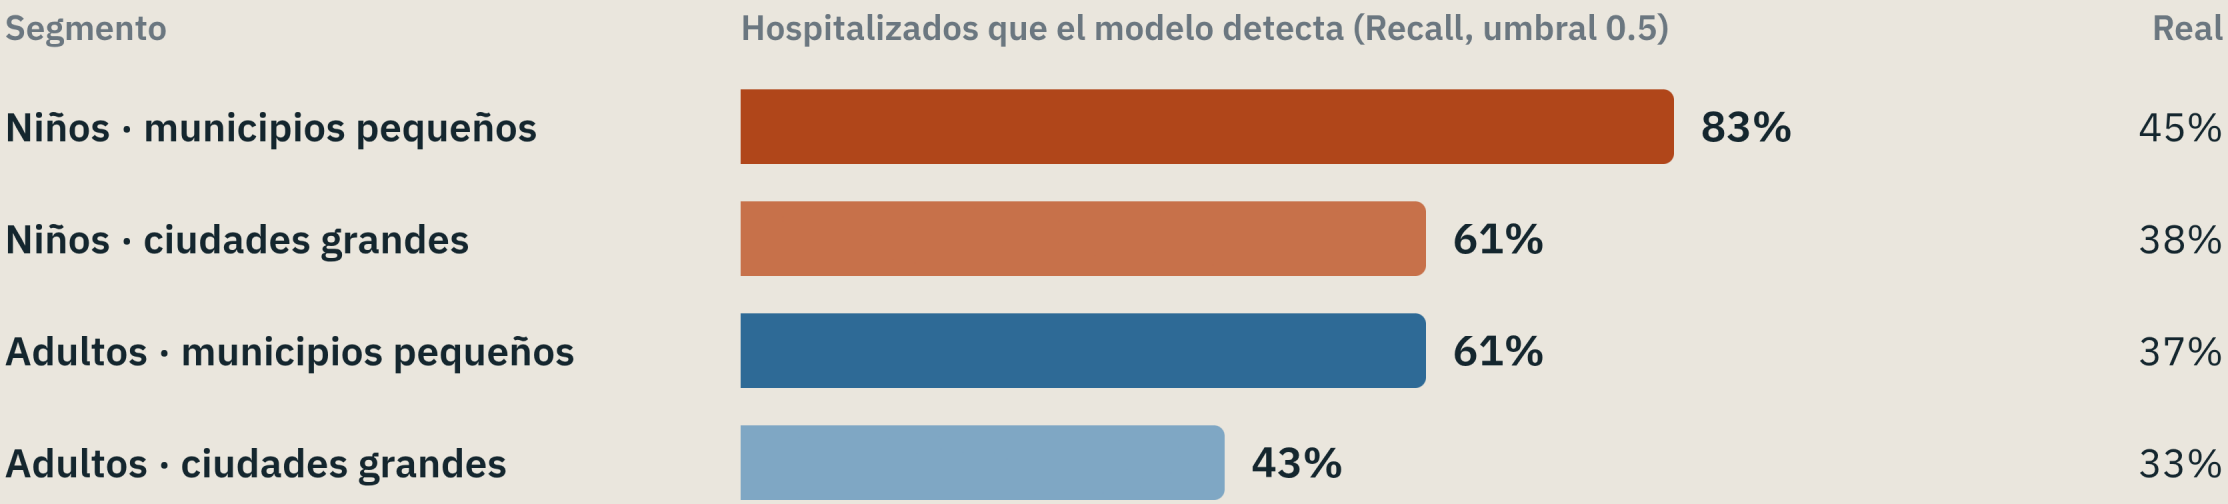
Adultos · ciudades grandes

22% de los casos · 73% contributivo · urbano

Número grande = **% hospitalizado** (promedio 38%). Silhouette ≈ 0.18: cortes de un continuo.

FASE D · MODELO × SEGMENTOS (TEST)

El modelo no detecta igual en todos los perfiles



El modelo ordena bien los perfiles (AUC 0.70–0.72 en cada uno), pero en adultos de ciudades grandes pierde más de la mitad de los casos: ahí conviene un umbral más bajo.

FASE D · CONCLUSIONES

Los datos sirven para priorizar, no para decidir sobre un paciente

1 **Los datos venían con trampas**: nulos disfrazados, edades en unidades mezcladas y variables que se registran después del caso. Un pipeline sin fuga de información fue la base de todo.

2 **Random Forest discrimina de forma moderada** (AUC ≈ 0.70): con umbral 0.45 detecta 78% de los hospitalizados y aguanta la prueba con 2025.

3 **Prioridad: niños de municipios pequeños**. Se hospitalizan 45% de las veces y concentran recursos escasos: seguimiento de signos de alarma en escuelas y centros de salud, y camas pediátricas antes del pico de mayo y junio.

FASE D · PRÓXIMOS PASOS

Qué haría mejores estos modelos

Más datos

Población DANE por municipio para calcular tasas reales, y clima (lluvia y temperatura).

Variables clínicas

Signos de alarma y comorbilidades disponibles al momento de la consulta.

Mejores modelos

Gradient Boosting, búsqueda de hiperparámetros más amplia y probabilidades calibradas.

Mejor segmentación

K-Prototypes o distancia de Gower, para que sexo, etnia y grupos poblacionales también cuenten.

Gracias. ¿Preguntas?